



Universidad
Internacional
de Valencia

Plataforma de Monitoreo de Calidad del Aire en Tiempo Real Basado en Lógica Difusa

Titulación:
Master Universitario en
Inteligencia Artificial
Curso académico
2025 – 2026

Alumno/a: Velasteguí
Izurieta, Homero Javier
D.N.I: 1804326534
Director/a de TFM: Msc.
Altamiranda Junior PhD.

Convocatoria:
Primera

Índice

Resumen	6
Abstract	7
1. Introducción	8
2. Objetivos	11
3. Estado del Arte	12
3.1. Síntesis Metodológica de la Revisión	12
3.2. Hallazgos del Estado del Arte Relevantes para el TFM	12
3.3. Vacíos del Estado del Arte	14
3.4. Antecedentes Comparables para Esta Investigación	15
3.5. Implicaciones para el Diseño de la Propuesta	17
4. Marco Teórico	19
4.1. AQI, Contaminantes Atmosféricos y Variables Meteorológicas	19
4.2. Modelos de Lógica Difusa	22
4.3. Modelos de Regresión Supervisada	28
4.4. Datasets Públicos de Calidad del Aire	30
5. Desarrollo del Proyecto y Resultados	35
5.1. Planteamiento del Problema	35
5.2. Metodología	37
5.3. Desarrollo del Proyecto	43
5.4. Resultados	52
5.5. Discusión	59
6. Conclusiones y Trabajos Futuros	62
7. Referencias	64
.	64
Lista de Acrónimos	68
Anexo I	70
Anexo II	72
Anexo III	75
Anexo IV	81

Índice de figuras

1.	Comparación conceptual de familias FIS para diseño de sistemas de calidad del aire. Elaboración propia.	24
2.	Flujo general de inferencia difusa para sistemas de calidad del aire. Elaboración propia.	24
3.	Representación de funciones de pertenencia y números borrosos en un FIS. Elaboración propia.	25
4.	Comparación de salida en Mamdani (centroide) y Sugeno/TSK (promedio ponderado). Elaboración propia.	26
5.	Elementos estructurales e interpretación funcional de ANFIS. Elaboración propia.	27
6.	Roadmap temporal del TFM por fases, actividades e hitos principales. Elaboración propia.	43
7.	Arquitectura funcional implementada del módulo AQRisk. Elaboración propia.	44
8.	Flujo de ejecución del prototipo implementado. Elaboración propia.	45
9.	Estructura de decisión implementada en el núcleo IA del módulo. Elaboración propia.	49
10.	Vista principal del <i>dashboard</i> para la corrida controlada <i>diffuse_overlap</i> . La captura deja visibles el panel de control, la lectura ejecutiva del episodio y el resumen de la corrida, que sirven como punto de entrada antes de abrir las vistas analíticas. Elaboración propia.	53
11.	Lectura analítica del <i>dashboard</i> sobre la corrida controlada <i>urban_escalation</i> . Las subfiguras condensan la base normativa del episodio, la reexpresión de esa base en la escala de salida del sistema y el papel de las variables auxiliares que enriquecen la decisión. Elaboración propia.	54
12.	Modal de <i>Trazabilidad</i> para el escenario controlado <i>diffuse_overlap</i> . La captura muestra cuatro reglas de la base principal con fuerzas de disparo distintas y, en paralelo, una regla contextual crisp evaluada sin escalado, lo que permite separar con claridad inferencia difusa principal y modulación contextual posterior. Elaboración propia.	55
13.	Distribución de reglas activadas en la corrida controlada <i>diffuse_overlap</i> . La evaluación muestra cuatro reglas efectivamente disparadas, con una regla dominante y tres aportes secundarios, lo que confirma que el motor principal combina zonas de solape en lugar de colapsar a una única regla. Elaboración propia.	56

14. Lectura interna de la corrida *diffuse_overlap*. Las subfiguras muestran la evaluación que se está explicando: la agregación del motor principal y la posición del episodio dentro de las tres variables lingüísticas que alimentan la inferencia. Elaboración propia. 56
15. Modal de *Explicabilidad* para el escenario controlado *urban_escalation*. La vista resume la inferencia principal y documenta por separado la capa contextual crisp mediante bandas, términos activos, matriz de reglas 3×3 y guardarraíl particulado. Elaboración propia. 57
16. Comparación entre salida principal y salida final en la evaluación controlada *urban_escalation*. La figura muestra explícitamente la evaluación presentada en este bloque: la capa contextual eleva la salida final respecto de la salida principal y hace visible el efecto del escalado sobre un episodio diseñado para activar esa condición. Elaboración propia. 58

Índice de cuadros

1.	Antecedentes comparables derivados del SLR para contrastar la propuesta del TFM.	16
2.	Síntesis comparativa de datasets públicos de calidad del aire utilizados como referencia metodológica. Elaboración propia.	32
3.	Marco PICO utilizado para la revisión del estado del arte. Elaboración propia.	38
4.	Resumen por bloques de la base principal de 54 reglas del motor difuso.	50
5.	Base contextual de 9 reglas para temperatura y humedad.	50
6.	Verificación funcional actual del prototipo implementado.	52
7.	Checklist de evaluación de calidad adaptado de Kitchenham (2007), con aplicación condicionada por subtipo cuantitativo. Elaboración propia.	70
8.	Diccionario operativo de campos de la matriz final de extracción de datos.	72
9.	Directriz D3: tabla principal de evidencia cuantitativa (k/n/ %; n=19). Elaboración propia.	75
10.	Resultados de desempeño: frecuencia de métricas en grupos comparables core (k/n/ %; n=19). Elaboración propia.	79
11.	Base principal de 54 reglas del motor difuso implementado.	81

Resumen

Este Trabajo Fin de Máster desarrolla un módulo para monitoreo de calidad del aire orientado a la evaluación del riesgo y a la generación de alertas en entornos urbanos. La propuesta parte de una revisión sistemática de la literatura sobre sistemas de inferencia difusa aplicados a monitoreo en tiempo real, con el fin de identificar variables dominantes, enfoques difusos recurrentes, arquitecturas operativas y vacíos metodológicos que condicionan el diseño de la solución. A partir de esa evidencia se definió un artefacto híbrido que combina una capa normativa de cálculo del índice de calidad del aire, una capa de inferencia difusa principal orientada a interpretar concurrencia y persistencia, y una capa contextual desacoplada basada en reglas para temperatura y humedad.

La implementación se materializó en un prototipo ejecutable denominado *AQRisk*, construido en Python mediante una arquitectura modular. El sistema integra ingesta de datos abiertos, preparación y control de calidad, cálculo del AQI con base en *AQI Breakpoints* de *EPA/AQS*, un motor Mamdani con una base principal de 54 reglas, una base contextual crisp de 9 reglas y un módulo de alertamiento trazable. Como complemento, se desarrolló una interfaz web para control de entrada, visualización de resultados, explicabilidad del razonamiento y revisión histórica de ejecuciones.

Los resultados actuales muestran que el prototipo ejecuta el flujo completo del artefacto, conserva trazabilidad por capas, reglas y variables derivadas, y permite validar escenarios controlados y consultas reales sobre datos abiertos. El aporte principal del trabajo consiste en articular, dentro de un mismo marco reproducible, cálculo normativo, inferencia difusa explicable, alertamiento interpretable e interfaz de supervisión para apoyo a la decisión.

Palabras clave: calidad del aire, lógica difusa, AQI, monitoreo en tiempo real, alertamiento, datos abiertos, explicabilidad.

Abstract

This Master's Thesis develops an air-quality monitoring module oriented to risk assessment and alert generation in urban environments. The proposal is grounded on a systematic literature review of fuzzy inference systems applied to real-time monitoring in order to identify dominant variables, recurring fuzzy approaches, operational architectures, and methodological gaps that shape the design of the solution. Based on that evidence, a hybrid artefact was defined, combining a normative air-quality-index layer, a main fuzzy inference layer aimed at interpreting pollutant concurrence and temporal persistence, and a decoupled rule-based contextual layer for temperature and humidity.

The implementation was materialized in an executable prototype named *AQRisk*, built in Python through a modular architecture. The system integrates open-data ingestion, data preparation and quality control, AQI computation based on the *EPA/AQS AQI Breakpoints*, a Mamdani engine with a 54-rule main base, a 9-rule crisp contextual base, and a traceable alerting module. In addition, a web interface was developed to control inputs, visualize outputs, explain the reasoning process, and review execution history.

Current results show that the prototype executes the complete pipeline, preserves traceability by layers, rules, and derived variables, and supports both controlled scenarios and real open-data queries. The main contribution of the work lies in articulating, within a single reproducible framework, normative computation, explainable fuzzy inference, interpretable alerting, and a supervision interface for decision support.

Keywords: air quality, fuzzy logic, AQI, real-time monitoring, alerting, open data, explainability.

1. Introducción

La calidad del aire se ha consolidado como un problema técnico, sanitario y de gestión pública que exige sistemas de monitoreo capaces de producir información útil para decisiones operativas en tiempo real. En este TFM, ese reto se aborda mediante la propuesta titulada Plataforma de Monitoreo de Calidad del Aire en Tiempo Real Basado en Lógica Difusa, que mide contaminantes y variables ambientales, consolida el AQI con base normativa EPA/AQS, aplica una inferencia difusa principal para interpretar el riesgo y complementa esa salida con una capa contextual basada en reglas para modularla cuando existen variables ambientales disponibles. En este contexto, los índices de calidad del aire (AQI) han sido ampliamente utilizados para traducir concentraciones de contaminantes en categorías interpretables por autoridades y ciudadanía. Sin embargo, revisiones de amplio alcance reportan una fragmentación metodológica persistente: diferencias en contaminantes considerados, escalas, umbrales, funciones de agregación y criterios de interpretación entre países y ciudades, lo que reduce la comparabilidad y genera ambigüedad en la lectura del riesgo (K y Kumar, 2022; Suman, 2020). En particular, se ha documentado que varios enfoques subestiman condiciones reales cuando priorizan un único contaminante dominante, y que muchas formulaciones no incorporan adecuadamente efectos combinados entre contaminantes ni escenarios de exposición de baja intensidad pero sostenida (K y Kumar, 2022).

Sobre esa base, la literatura reciente muestra un desplazamiento hacia enfoques de lógica difusa para tratar incertidumbre, imprecisión y no linealidad en datos ambientales. Esta línea tiene sustento conceptual en el marco de variables lingüísticas y reglas difusas para sistemas complejos y difícilmente modelables con esquemas estrictamente deterministas (Zadeh, 1973). En aplicaciones contemporáneas de monitoreo de aire, se observan resultados prometedores en clasificación, soporte a la decisión y, en algunos casos, predicción usando FIS, ANFIS y variantes híbridas (Seibert y cols., 2024; Bushnag, 2023; Andrianto, Purnomo, y Irawan, 2024; Saleem, Shingari, Farooq, Mago, y Khan, 2024; Lingaraj y cols., 2025). No obstante, la evidencia también revela divergencias relevantes entre autores: algunos trabajos privilegian precisión de clasificación en datasets concretos (Seibert y cols., 2024), otros priorizan control ambiental en espacios cerrados y automatización de ventilación (Bushnag, 2023), otros enfatizan implementación IoT con desempeño operativo local (Andrianto y cols., 2024; Saleem y cols., 2024), mientras que propuestas más recientes se orientan a eficiencia de red y enrutamiento inteligente en WSN para ciudades inteligentes (Lingaraj y cols., 2025). Esta heterogeneidad confirma que el campo está activo, pero todavía disperso en sus criterios de diseño y validación.

En relación con los vacíos y limitaciones explícitamente reportados por los propios estudios, persisten cuatro problemas de fondo. Primero, la falta de estandarización y trazabilidad metodológica para comparar enfoques de forma justa entre contextos, sensores y configuraciones experimentales (K y Kumar, 2022; Suman, 2020). Segundo, limitaciones de generalización: varios desarrollos se validan en entornos localizados o con cobertura restringida, con necesidad de pruebas en escenarios más diversos y escalables (Seibert y cols., 2024; Lingaraj y cols., 2025). Tercero, restricciones técnicas que afectan despliegue real, como calibración de sensores de bajo costo, deriva de medición, latencia, consumo energético, y ausencia de mecanismos robustos de seguridad en arquitectura distribuida (Lingaraj y cols., 2025). Cuarto, una brecha entre el desempeño reportado en simulación/prototipo y la documentación reproducible de decisiones de diseño, criterios de evaluación y robustez estadística (Andrianto y cols., 2024; Saleem y cols., 2024; Lingaraj y cols., 2025). Estos vacíos dificultan pasar de soluciones puntuales a plataformas confiables y transferibles.

Desde esta perspectiva, la motivación de esta investigación es doble. Por un lado, se requiere una síntesis rigurosa de evidencia reciente que permita identificar con precisión qué variables, diseños difusos y arquitecturas de plataforma han mostrado mayor utilidad práctica en monitoreo de calidad del aire en tiempo real. Por otro lado, esa síntesis debe traducirse en decisiones de ingeniería para una propuesta técnica concreta, evitando que el estado del arte quede desconectado de la implementación. En consecuencia, el trabajo describe antecedentes y busca convertir evidencia dispersa en criterios de diseño trazables para una integrarlos en una solución aplicable.

A partir de los antecedentes y de los vacíos observados, este estudio establece como brecha central la ausencia de un marco integrador que conecte, de manera explícita y reproducible, cuatro niveles que suelen tratarse por separado: (i) selección y tratamiento de variables ambientales y contaminantes, (ii) diseño del sistema de inferencia difusa y su rol en la toma de decisiones, (iii) evaluación flexible del riesgo mediante términos lingüísticos, y (iv) arquitectura de monitoreo en tiempo real con capacidad de alertamiento preventivo bajo condiciones reales de despliegue. Esta brecha es crítica porque afecta a la calidad de la revisión sistemática y a la viabilidad técnica de la plataforma que se propone desarrollar.

Con ese marco, el objetivo general que guía todo el trabajo es desarrollar un módulo de monitoreo de calidad del aire para apoyar la evaluación del riesgo y la generación de alertas, mediante inferencia difusa y datos abiertos de redes de monitoreo ambiental, en entornos urbanos. En coherencia con ello, la pregunta general de investigación del TFM es: ¿cómo desarrollar un módulo de monitoreo de calidad del aire que apoye la evaluación del riesgo y la generación de alertas mediante inferencia difusa y datos abiertos de redes de monitoreo ambiental en entornos urbanos? La fase de revisión sistemática formula, además, una pregunta específica orientada a caracterizar el estado del arte y a derivar

criterios de diseño para la propuesta.

Bajo esta orientación, las investigaciones referentes se interpretan como complementarios más que excluyentes. Los estudios de revisión de AQI aportan diagnóstico de inconsistencias estructurales y criterios para evitar comparaciones engañosas (K y Kumar, 2022; Suman, 2020); los trabajos de base difusa aportan fundamento para modelar incertidumbre en dominios complejos (Zadeh, 1973); y los desarrollos aplicados en IoT/WSN muestran rutas tecnológicas concretas para captura, inferencia y operación en campo (Seibert y cols., 2024; Bushnag, 2023; Andrianto y cols., 2024; Saleem y cols., 2024; Lingaraj y cols., 2025). La contribución de este TFM es precisamente cerrar el ciclo entre esos tres planos: evidencia, método y propuesta técnica.

El documento se estructura de la siguiente manera. Tras esta introducción, la sección de objetivos delimita el alcance del estudio y los resultados esperados. Luego, en el estado del arte y marco teórico se presenta la síntesis derivada de la revisión sistemática. A continuación, en desarrollo del proyecto y resultados se describe la metodología aplicada, incluyendo la revisión sistemática como primera fase del trabajo, junto con el diseño de la solución, su implementación y el esquema de validación. Finalmente, la sección de conclusiones y trabajos futuros recoge los principales hallazgos, limitaciones del estudio y líneas de continuidad para la evolución de la propuesta.

2. Objetivos

Los objetivos establecidos para este Trabajo Fin de Máster se formulan de manera específica, realista y alcanzable, en coherencia con el alcance metodológico del estudio y con el desarrollo progresivo de sus fases.

Objetivo general

Desarrollar un módulo de monitoreo de calidad del aire para apoyar la evaluación del riesgo y la generación de alertas, mediante inferencia difusa y datos abiertos de redes de monitoreo ambiental, en entornos urbanos.

Objetivos específicos

1. Caracterizar, mediante revisión sistemática de la literatura, las variables de calidad del aire, los enfoques de inferencia difusa y las arquitecturas de monitoreo en tiempo real reportadas en estudios recientes.
2. Diseñar la arquitectura funcional del módulo de monitoreo, definiendo el flujo de datos, el esquema de inferencia difusa y la lógica de alertamiento.
3. Implementar el módulo propuesto, integrando adquisición de datos abiertos, procesamiento de variables ambientales y motor de inferencia difusa.
4. Validar el comportamiento del módulo en escenarios urbanos, mediante métricas y casos de prueba orientados a la evaluación del riesgo y la generación de alertas.

3. Estado del Arte

3.1. Síntesis Metodológica de la Revisión

El estado del arte de este TFM se apoya en una revisión sistemática de la literatura desarrollada como estudio independiente y enviada a evaluación en la revista *Applied Sciences*. La revisión siguió la guía de Kitchenham (Kitchenham y Charters, 2007) y el estándar PRISMA 2020 (Page y cols., 2021), con una estrategia de búsqueda delimitada mediante el modelo PICO. La consulta se ejecutó en Scopus, Web of Science e IEEE Xplore, con restricción a publicaciones en inglés entre 2021 y 2026.

La búsqueda inicial recuperó 240 registros. Tras depuración de duplicados, cribado por título y resumen, recuperación de texto completo y evaluación de elegibilidad, el corpus final quedó constituido por 19 estudios primarios. En esta memoria se presenta la parte del estudio que resulta necesaria para tres propósitos: caracterizar el campo reciente, justificar la brecha de investigación y derivar criterios de diseño para el módulo de monitoreo planteado en este TFM.

3.2. Hallazgos del Estado del Arte Relevantes para el TFM

Variables de entrada y fuentes de datos

La literatura reciente converge en un conjunto acotado de variables para evaluación de la calidad del aire en sistemas difusos. $PM_{2,5}$, CO, CO_2 y PM_{10} aparecen con alta frecuencia en tareas de clasificación, estimación y predicción, mientras temperatura y humedad se emplean como variables de apoyo en arquitecturas interiores y urbanas (Andrianto y cols., 2024; Saleem y cols., 2024; Haidar y cols., 2025; Saini, Dutta, y Marques, 2022b; Istiqomah, Yuliana, y Santoso, 2021; Zareb y cols., 2021). Esta pauta se observa en sistemas de monitoreo IoT con clasificación AQI/ISPU basados en $PM_{2,5}$, PM_{10} y CO (Andrianto y cols., 2024), en propuestas urbanas que combinan SO_2 , NO_2 , CO, O_3 y PM_{10} (Saleem y cols., 2024), y en esquemas de pronóstico o ajuste donde $PM_{2,5}$ se combina con covariables microclimáticas y contaminantes adicionales (Kowalski, Casari, y Po, 2026; Saini y cols., 2022b). Para este TFM, esta evidencia delimita un núcleo de variables pertinente para diseñar un módulo urbano basado en datos abiertos y orientado a evaluación del riesgo.

La revisión también muestra una diferencia metodológica importante entre adquisición directa y reutilización de datos abiertos. Predominan los estudios sustentados en sen-

sores propios o redes instrumentadas de bajo costo (Bushnag, 2023; Andrianto y cols., 2024; Sung, Aryani, y Sung-Jung, 2024; Istiqomah y cols., 2021; Zareb y cols., 2021). Los trabajos basados en datos públicos o en validación multi-localización son menos frecuentes, aunque aportan mejores condiciones de trazabilidad para contrastar generalización y comparabilidad (Haidar y cols., 2025; Kowalski y cols., 2026; Saini y cols., 2022b). Este punto es central para la propuesta del TFM, porque la procedencia del dato condiciona la reproducibilidad del módulo y la validez de su evaluación.

Inferencia difusa y modelado del riesgo

Los estudios revisados sitúan la inferencia difusa como núcleo de decisión del sistema. Las familias más recurrentes son Mamdani y ANFIS. Mamdani aparece asociada con mayor frecuencia a clasificación de calidad del aire, interpretación de categorías AQI y activación de alertas (Andrianto y cols., 2024; Istiqomah y cols., 2021; Zareb y cols., 2021). ANFIS aparece en tareas de predicción, ajuste de medida y reducción de error sobre series de contaminantes o sensores de bajo costo (Haidar y cols., 2025; Kowalski y cols., 2026; Saini y cols., 2022b). Esta distinción resulta decisiva para el TFM, porque separa una lógica de diseño orientada a trazabilidad de reglas y soporte a la decisión de otra centrada en ajuste guiado por datos.

La literatura mantiene heterogeneidad en aspectos críticos del diseño difuso. Las bases de reglas, las funciones de pertenencia y el criterio de modelado del riesgo se reportan con distinto nivel de detalle. En varios estudios, la relación entre regla, clase AQI y respuesta operativa queda explícita (Bushnag, 2023; Andrianto y cols., 2024; Sung y cols., 2024; Istiqomah y cols., 2021; Zareb y cols., 2021). En otros, el énfasis se desplaza hacia desempeño predictivo o simplificación del modelo, como ocurre en trabajos basados en ANFIS o reducción explicable de reglas (Haidar y cols., 2025; Kowalski y cols., 2026). Esta diferencia afecta la auditabilidad de los resultados y limita la comparación entre sistemas que usan la misma etiqueta difusa con decisiones internas distintas. Para un módulo destinado a apoyar evaluación del riesgo y generación de alertas, esta observación refuerza la necesidad de un núcleo difuso interpretable y documentado.

Plataformas de monitoreo y operación en tiempo real

El corpus revisado confirma la presencia de una base tecnológica relativamente estable para monitoreo difuso en tiempo real o casi tiempo real. Son frecuentes las arquitecturas IoT con nodo de adquisición, procesamiento local o híbrido y publicación en nube o tablero web (Bushnag, 2023; Andrianto y cols., 2024; Sung y cols., 2024; Saini y cols., 2022b; Zareb y cols., 2021). En (Sung y cols., 2024), el flujo integra sensores, inferencia, visualización y actuación sobre el ambiente mediante ESP32 y Firebase. En (Saini y cols., 2022b), la red IoT alimenta un portal web para seguimiento de IAQ y pronóstico de PM_{2,5}. En (Zareb y cols., 2021), el sistema combina sensores de bajo costo, calibración difusa y estimación de AQI en un entorno doméstico.

La operación continua no implica el mismo nivel de integración en todos los casos. Algunos trabajos reportan monitoreo y publicación de resultados con respuesta por umbral o recomendación operativa (Bushnag, 2023; Sung y cols., 2024; Istiqomah y cols., 2021; Zareb y cols., 2021). Otros concentran el aporte en el modelo predictivo o en la estructura de red y dejan en segundo plano la descripción del ciclo completo de adquisición, procesamiento, publicación y mantenimiento (Haidar y cols., 2025; Lingaraj y cols., 2025). Para este TFM, la diferencia es sustantiva: el objetivo consiste en formular un modelo de inferencia y además desarrollar un módulo de monitoreo con flujo funcional completo y salida útil para alertamiento.

3.3. Vacíos del Estado del Arte

La síntesis del corpus revisado permite identificar un conjunto de vacíos que trascienden a estudios aislados y condicionan tanto la comparabilidad de resultados como el diseño de nuevas propuestas. Estos vacíos, que se presentan a continuación, afectan la procedencia del dato, la amplitud del contexto evaluado, el nivel de integración operativa y la forma en que se reporta la validación.

- **Generalización externa insuficiente.** La literatura presenta resultados favorables dentro del entorno de prueba de cada estudio, pero la validación en más de una ciudad, más de una red de sensores o más de una ventana temporal sigue siendo escasa (Seibert y cols., 2024; Haidar y cols., 2025; Kowalski y cols., 2026; Saini y cols., 2022b). Esta limitación ya había sido anticipada en revisiones de AQI, donde la comparabilidad entre modelos y contextos aparece como problema estructural (K y Kumar, 2022; Suman, 2020).
- **Comparabilidad metodológica limitada.** Los trabajos difieren en variables de entrada, tipo de salida, métrica reportada, partición de datos y nivel de detalle sobre la configuración difusa. En consecuencia, dos estudios pueden informar alto desempeño sin estar evaluando la misma tarea ni bajo un protocolo equivalente (K y Kumar, 2022; Suman, 2020; Haidar y cols., 2025; Kowalski y cols., 2026; Saini y cols., 2022b). Esta heterogeneidad dificulta atribuir el rendimiento al diseño del sistema con la precisión necesaria para reutilizarlo en otro contexto.
- **Cobertura restringida de variables y contextos.** El núcleo de contaminantes y co-variables se concentra en configuraciones compactas, útiles para despliegue práctico, pero con menor amplitud química y contextual (Andrianto y cols., 2024; Saleem y cols., 2024; Saini y cols., 2022b; Istiqomah y cols., 2021; Zareb y cols., 2021). En varios casos, la evaluación se desarrolla en contextos interiores o locales, con poca discusión sobre transferencia a escenarios urbanos abiertos o a fuentes públicas heterogéneas (Bushnag, 2023; Sung y cols., 2024; Zareb y cols., 2021).

- **Integración operativa incompleta.** La literatura incluye ejemplos con monitoreo, tablero y respuesta automática (Bushnag, 2023; Sung y cols., 2024; Istiqomah y cols., 2021; Zareb y cols., 2021), pero también trabajos en los que el modelo queda planteado como componente analítico potencial sin cierre completo de la cadena operativa (Haidar y cols., 2025; Saini y cols., 2022b). Para una propuesta orientada a soporte de decisión, esta diferencia es crítica porque la utilidad práctica depende de la trazabilidad del flujo completo.
- **Reporte desigual de calibración, interpretabilidad y eficiencia operativa.** Estudios recientes muestran avances claros en ajuste explicable de sensores de bajo costo (Kowalski y cols., 2026) y en eficiencia de red para WSN urbanas (Lingaraj y cols., 2025). Sin embargo, esas dimensiones no se reportan de forma homogénea en el conjunto del campo. Persisten diferencias importantes en la documentación de reducción de reglas, deriva de sensores, tiempos de inferencia, consumo de recursos y desempeño de comunicación (Kowalski y cols., 2026; Lingaraj y cols., 2025). Esta dispersión limita la reproducibilidad técnica.

Estos vacíos técnicos describen un campo activo, pero todavía fragmentado en variables, diseño difuso, arquitectura y validación. Esta evidencia justifica el objetivo del TFM: desarrollar un módulo de monitoreo apoyado en datos abiertos, con inferencia difusa auditable y con criterios de evaluación comparables.

3.4. Antecedentes Comparables para Esta Investigación

La Tabla 1 reúne estudios del corpus que ofrecen puntos de comparación directos para esta investigación. La selección prioriza trabajos con afinidad en cuatro dimensiones: uso de datos trazables, núcleo difuso explícito, monitoreo en tiempo real o casi tiempo real, y generación de alertas o soporte a decisión.

Dentro de ese conjunto aparecen antecedentes centrados en predicción AQI urbana con datos públicos (Haidar y cols., 2025), ajuste explicable de $PM_{2.5}$ sobre múltiples localizaciones (Kowalski y cols., 2026), control ambiental industrial con integración IoT (Sung y cols., 2024), pronóstico interior con portal web (Saini y cols., 2022b), alertamiento local basado en reglas (Istiqomah y cols., 2021) y monitoreo automático indoor con FIS tipo 1 (Zareb y cols., 2021). Esta combinación permite contrastar la propuesta con estudios que cubren distintos puntos de la cadena, desde el modelado hasta la operación de plataforma, sin perder afinidad con el problema de monitoreo y decisión.

Estudio	Objetivo y contexto	Entradas y fuente de datos	Enfoque difuso y plataforma	Validación reportada	Límite relevante para contrastar con este TFM
(Haidar y cols., 2025)	Predicción de AQI en contexto urbano.	Datos ambientales y de contaminantes en tiempo real; el artículo destaca NO ₂ y CO como variables centrales.	Arquitectura híbrida con ANFIS dentro de un ensamble de aprendizaje automático.	Reporta $R^2 = 96\%$ en particiones aleatorizadas.	El trabajo plantea integración potencial en estaciones de monitoreo, pero no documenta un despliegue operativo completo.
(Kowalski y cols., 2026)	Ajuste de mediciones de PM _{2,5} de sensores de bajo costo en múltiples localizaciones.	PM _{2,5} y datos de co-localización con validación geográfica múltiple; publica software y datos en Zenodo.	ANFIS con reducción explicable de reglas; implementación en MATLAB.	Mantiene correlaciones de prueba entre 0.73 y 0.96 tras la poda de reglas.	Su foco está en calibración y ajuste de medida; no aborda alertamiento ni operación urbana de extremo a extremo.
(Sung y cols., 2024)	Control de calidad ambiental en fábrica inteligente.	Sensores ambientales conectados a ESP32-S y envío a Firebase.	Reglas difusas más aprendizaje por refuerzo profundo; monitoreo remoto por app/web.	Precisión de 91.16 %, pérdida de 1.64 % y tiempo de inferencia de 3 ms.	El dominio es industrial interior; la solución prioriza control local y eficiencia energética.
(Saini y cols., 2022b)	Pronóstico de PM _{2,5} interior con red IoT y portal web.	PM _{2,5} , CO ₂ , CO, temperatura y humedad; combina datos reales de distintas localizaciones y conjuntos de referencia.	ADFIST sobre red IoT y publicación en portal Vayurveda.	Contraste con múltiples conjuntos de datos y validación adicional frente a <i>benchmarks</i> .	El objetivo es pronóstico interior; la comparación interurbana abierta sigue siendo limitada.

Continued on next page

(Continued)

Estudio	Objetivo y contexto	Entradas y fuente de datos	Enfoque difuso y plataforma	Validación reportada	Límite relevante para contrastar con este TFM
(Istiqomah y cols., 2021)	Monitoreo de calidad del aire con nodo inteligente y alerta temprana.	CO, CO ₂ y CH ₄ en pruebas interiores y exteriores; transmisión por LoRa.	Fuzzy Tsukamoto en nodo sensor con Raspberry Pi como agregador.	Exactitud de 92.4 % para la clasificación del aire.	Trabaja con un conjunto reducido de variables y una semántica de alerta local.
(Zareb y cols., 2021)	Monitoreo automático de calidad del aire interior en hogar inteligente.	CO, PM, temperatura y humedad con sensores de bajo costo en entorno doméstico.	Sistema IoT de dos capas con FIS tipo 1 para calibración y estimación de AQI.	Ensayos experimentales en vivienda; el artículo reporta efectividad del sistema implementado.	El estudio se centra en entorno interior y no desarrolla validación externa entre ciudades o fuentes abiertas.

Tabla 1. Antecedentes comparables derivados del SLR para contrastar la propuesta del TFM.

3.5. Implicaciones para el Diseño de la Propuesta

Los hallazgos del estado del arte delimitan decisiones de diseño que resultan difíciles de omitir en una propuesta orientada a monitoreo urbano, trazabilidad operativa y soporte a la decisión. A partir de las limitaciones detectadas en validación, comparabilidad, explicitud del núcleo difuso e integración de plataforma (K y Kumar, 2022; Suman, 2020; Kowalski y cols., 2026; Sung y cols., 2024; Saini y cols., 2022b; Zareb y cols., 2021), la propuesta adopta los siguientes criterios:

1. La fuente de datos debe ser trazable y reutilizable, porque la literatura muestra una dependencia excesiva de instrumentación local con validación acotada (Haidar y cols., 2025; Kowalski y cols., 2026; Saini y cols., 2022b).
2. El componente difuso debe mantener reglas, funciones de pertenencia y criterios de salida explícitos, dado que la auditabilidad sigue siendo un punto débil en parte del campo (Bushnag, 2023; Andrianto y cols., 2024; Kowalski y cols., 2026; Zareb y cols., 2021).
3. La propuesta debe tratar el monitoreo como un flujo operativo completo, con ingesta, procesamiento, inferencia, publicación y alertamiento documentados (Sung y cols., 2024; Istiqomah y cols., 2021; Zareb y cols., 2021).

4. La validación debe reportarse con métricas compatibles con la salida objetivo y con una partición de datos claramente declarada (K y Kumar, 2022; Suman, 2020; Haidar y cols., 2025; Saini y cols., 2022b).
5. La solución debe incorporar control de calidad de datos y una estrategia de evaluación que permita observar estabilidad fuera de un único contexto de prueba (Kowalski y cols., 2026; Lingaraj y cols., 2025).

4. Marco Teórico

Con base en los hallazgos del estado del arte, esta síntesis conceptual fija los fundamentos técnicos que sostienen la propuesta: definición operativa del AQI, estructura de los modelos difusos, criterios de evaluación predictiva y características de los datasets públicos utilizados en estudios recientes.

4.1. AQI, Contaminantes Atmosféricos y Variables Meteorológicas

El índice de calidad del aire (AQI) es un indicador sintético y adimensional diseñado para transformar concentraciones de contaminantes atmosféricos en una escala única de interpretación del riesgo (K y Kumar, 2022; Suman, 2020). Su finalidad es convertir mediciones técnicas en información comprensible y utilizable para vigilancia ambiental, comunicación pública y toma de decisiones en salud y gestión de la calidad del aire (K y Kumar, 2022; Suman, 2020).

El AQI opera como un mecanismo de normalización y agregación, parte de concentraciones observadas, las relaciona con valores de referencia normativos y produce un valor integrado que resume la condición ambiental en un instante o periodo de análisis (K y Kumar, 2022; Suman, 2020). Esta transformación resuelve un problema central de interpretación, porque los contaminantes presentan unidades, escalas y niveles de impacto diferentes; por ello, una lectura directa de concentraciones aisladas no ofrece, por sí sola, una visión clara del nivel de riesgo global.

En términos de propósito, el AQI cumple las siguientes funciones:

- **Función informativa:** comunica de forma estandarizada el estado de la calidad del aire.
- **Función preventiva:** alerta sobre escenarios de deterioro para reducir exposición poblacional.
- **Función operativa:** sirve como variable de referencia para sistemas de monitoreo, alerta y control ambiental.

Por esta razón, el AQI se considera una pieza conceptual clave en arquitecturas de evaluación y gestión de contaminación del aire (K y Kumar, 2022; Suman, 2020).

Contaminantes y variables Los modelos de AQI se construyen con contaminantes criterio que representan el nivel de exposición de la población y el riesgo sanitario asociado (K y Kumar, 2022; Suman, 2020). De manera general, el núcleo más extendido incluye PM2.5, PM10, O3, NO2, SO2 y CO; en algunos marcos regulatorios también se incorpora Pb (K y Kumar, 2022; Suman, 2020).

Las definiciones técnicas de estos contaminantes, en el contexto del AQI, son:

- **PM2.5:** material particulado fino con diámetro aerodinámico menor o igual a $2.5 \mu m$, capaz de penetrar regiones profundas del sistema respiratorio.
- **PM10:** material particulado inhalable con diámetro aerodinámico menor o igual a $10 \mu m$, útil para caracterizar carga de partículas gruesas y fracción respirable.
- **O3** (ozono troposférico): contaminante secundario formado por reacciones fotoquímicas entre precursores (principalmente NOx y compuestos orgánicos) bajo radiación solar.
- **NO2** (dióxido de nitrógeno): gas reactivo asociado a procesos de combustión (tráfico, calderas y fuentes estacionarias), relevante por su papel en irritación respiratoria y química atmosférica secundaria.
- **SO2** (dióxido de azufre): gas generado por combustibles con azufre y procesos industriales; se asocia a irritación respiratoria y formación de sulfatos/lluvia ácida.
- **CO** (monóxido de carbono): gas producto de combustión incompleta, incluido en esquemas AQI por su efecto sobre transporte de oxígeno en sangre.
- **Pb** (plomo): metal pesado tóxico considerado en algunos marcos de calidad del aire por su impacto sistémico y neurológico.

Además del núcleo anterior, existen modelos de AQI que incorporan contaminantes o términos compuestos adicionales (por ejemplo, TSP, NOx o combinaciones ponderadas) para contextos específicos de evaluación (K y Kumar, 2022; Suman, 2020). Por separado, los modelos de calidad de aire interior suelen ampliar entradas con CO2, TVOC y variables ambientales; estas extensiones fortalecen la lectura del entorno, aunque no siempre forman parte del AQI regulatorio clásico.

Variables ambientales En los modelos de calidad del aire, las variables ambientales funcionan como covariables transversales para interpretar la dinámica de los contaminantes y la variación del índice en el tiempo y en el espacio (K y Kumar, 2022; Suman, 2020). La temperatura del aire condiciona procesos físico-químicos atmosféricos y modifica patrones temporales de concentración; la humedad relativa influye en el comportamiento

del material particulado y en la respuesta de los aerosoles; y el viento, tanto en velocidad como en dirección, determina la dispersión, el transporte y la posible procedencia espacial de episodios de contaminación (K y Kumar, 2022; Suman, 2020).

A este conjunto se suman variables de estabilidad atmosférica y presión, que ayudan a distinguir escenarios de mezcla o estancamiento del aire. Por ello, estas variables no se tratan como entradas accesorias, sino como componentes de contexto que permiten interpretar con mayor precisión el valor del AQI y su significado operativo (K y Kumar, 2022; Suman, 2020).

Cálculo y categorías del AQI El cálculo del AQI se estructura en dos etapas. En la primera etapa, la concentración observada de cada contaminante se transforma en un subíndice normalizado; en la segunda etapa, los subíndices se combinan para obtener un valor único de calidad del aire (K y Kumar, 2022; Suman, 2020). Esta estructura permite integrar variables con unidades y rangos distintos en una salida común.

En un enfoque dependiente de estándares de calidad del aire, una formulación reportada para el subíndice es:

$$Q_i = 10 \left(\frac{C_i}{S_i} \right), \quad (1)$$

donde Q_i es la calificación del contaminante i , C_i es la concentración observada y S_i es el valor estándar de referencia. A partir de esos subíndices, el índice global puede expresarse como:

$$AQI = (Q_1 \cdot Q_2 \cdots Q_n)^{1/n}, \quad (2)$$

con n contaminantes considerados (Suman, 2020).

Otro esquema ampliamente utilizado emplea concentraciones de quiebre (*breakpoints*) e interpolación lineal segmentada para mapear cada concentración al subíndice correspondiente (K y Kumar, 2022; Suman, 2020). En el marco regulatorio de la *United States Environmental Protection Agency* (EPA), esta transformación se formaliza mediante una interpolación lineal por tramos entre el intervalo de concentración aplicable y el intervalo AQI asociado (United States Environmental Protection Agency, 2024). La expresión utilizada es:

$$I_p = \frac{I_{Hi} - I_{Lo}}{BP_{Hi} - BP_{Lo}} (C_p - BP_{Lo}) + I_{Lo}, \quad (3)$$

donde C_p es la concentración representativa del contaminante p , BP_{Lo} y BP_{Hi} son los *breakpoints* inferior y superior del tramo aplicable, e I_{Lo} e I_{Hi} son los límites del subíndice asociados a ese tramo (United States Environmental Protection Agency, 2024). En la práctica, los valores concretos de esos *breakpoints* y de los intervalos AQI se obtienen de las tablas regulatorias publicadas por EPA/AQS (United States Environmental Protection Agency, 2026). Después, los subíndices se agregan con una regla definida por el modelo

y el marco regulatorio; en el esquema EPA/AQS la consolidación se basa en el mayor subíndice calculado, de modo que el contaminante dominante fija el valor final del índice (United States Environmental Protection Agency, 2024, 2026).

La interpretación final del AQI se comunica mediante categorías cualitativas de riesgo asociadas a intervalos numéricos y a recomendaciones sanitarias para la población. En el esquema estadounidense documentado por EPA, la escala se organiza en seis bandas: *Good* (0–50), *Moderate* (51–100), *Unhealthy for Sensitive Groups* (101–150), *Unhealthy* (151–200), *Very Unhealthy* (201–300) y *Hazardous* (301–500) (United States Environmental Protection Agency, 2024). Estas categorías entregan una función descriptiva al constituir el vínculo operativo entre concentración, nivel de riesgo y comunicación pública.

Las diferencias entre normas y jurisdicciones se originan en los parámetros reglamentarios que define cada autoridad ambiental: conjunto de contaminantes obligatorios, valores de quiebre (*breakpoints*), periodos de promediación, intervalos categoriales y denominación de clases (K y Kumar, 2022; Suman, 2020). En consecuencia, la interpretación del AQI depende de la norma aplicada en cada país o región, y la comparación entre resultados exige declarar explícitamente el marco normativo de referencia. En el caso de EPA/AQS, los *breakpoints* publicados especifican para cada contaminante el tramo de concentración y el tramo AQI que alimentan la interpolación lineal del subíndice (United States Environmental Protection Agency, 2026).

Desde el punto de vista de implementación, el AQI puede entenderse como una cadena técnica de cuatro elementos: selección de contaminantes, normalización por estándar, agregación de subíndices y traducción a categorías de riesgo (K y Kumar, 2022; Suman, 2020). En el marco EPA/AQS, esa cadena culmina con una regla de consolidación por dominancia: el valor final del índice se fija por el mayor subíndice calculado entre los contaminantes criterio (United States Environmental Protection Agency, 2024, 2026). Esta precisión es importante para la propuesta desarrollada en esta memoria, porque el artefacto implementado adopta precisamente esas seis bandas categoriales como base normativa del AQI. Por ello, cualquier implementación orientada a monitoreo debe declarar de forma explícita contaminantes incluidos, valores de referencia, método de cálculo, regla de consolidación y esquema categorial, para asegurar trazabilidad y lectura correcta del resultado (K y Kumar, 2022; Suman, 2020). Sobre esta base se sustenta el siguiente tema, centrado en cómo la lógica difusa modela esa transición desde variables ambientales y de contaminación hacia salidas de decisión.

4.2. Modelos de Lógica Difusa

La lógica difusa se fundamenta en la representación de pertenencia gradual, donde cada elemento puede tomar un grado en el intervalo $[0, 1]$ dentro de un conjunto difuso (Zadeh,

1973; Olivas, 2003, 2019). Esta formulación permite modelar fenómenos con fronteras no nítidas y condiciones de transición continua, que son frecuentes en variables ambientales.

Sobre esa base, la inferencia difusa se construye mediante variables lingüísticas, funciones de pertenencia y reglas *if-then*. El flujo general comprende fuzzificación de entradas, evaluación de reglas en el motor de inferencia y defuzzificación para obtener una salida numérica utilizable en decisión o control (Saleem y cols., 2024; Olivas, 2019). Esta estructura proporciona trazabilidad entre conocimiento experto y salida del sistema.

En aplicaciones de calidad del aire, este marco se implementa de forma práctica para transformar lecturas de sensores en niveles de riesgo o estado ambiental. Se reportan implementaciones con inferencia Mamdani para operación en tiempo real y manejo de incertidumbre en entradas de contaminación (Andrianto y cols., 2024); también se presentan configuraciones neuro-difusas adaptativas para integrar aprendizaje sobre datos y ajuste del sistema de inferencia (Seibert y cols., 2024).

Familias principales de sistemas difusos

En sistemas difusos aplicados a calidad del aire se emplean tres familias principales: *Mamdani*, *Sugeno/TSK* y *ANFIS*. Comparten la misma base de conjuntos difusos, funciones de pertenencia y reglas, pero difieren en la forma de producir la salida final y en el mecanismo de ajuste del modelo (Seibert y cols., 2024; Andrianto y cols., 2024; Saleem y cols., 2024). Esa diferencia determina su uso en problemas orientados a interpretación, eficiencia computacional o aprendizaje con datos.

Mamdani utiliza reglas con consecuentes lingüísticos. Tras evaluar las reglas, se agregan los conjuntos de salida y se aplica defuzzificación para obtener un valor numérico (Andrianto y cols., 2024; Saleem y cols., 2024). Este enfoque mantiene una lectura directa de la lógica del sistema y favorece interpretación práctica de reglas.

Sugeno/TSK conserva antecedentes difusos en las reglas, pero define consecuentes numéricos (constantes o funciones de entrada). La salida global se obtiene por promedio ponderado de esos consecuentes, lo que reduce costo computacional en inferencia y facilita integración con bloques matemáticos de control.

ANFIS (*Adaptive Neuro-Fuzzy Inference System*) integra estructura difusa con entrenamiento sobre datos para ajustar parámetros del sistema, en especial funciones de pertenencia y pesos asociados a reglas (Seibert y cols., 2024). Este modelo incrementa capacidad de adaptación, aunque exige mayor control metodológico para conservar trazabilidad del proceso.

La selección práctica depende del objetivo del sistema: Mamdani cuando se prioriza interpretación de reglas, Sugeno/TSK cuando se prioriza inferencia eficiente y ANFIS cuando se requiere ajuste guiado por datos. La Figura 1 resume este contraste con foco

en criterios de diseño prácticos.



Figura 1. Comparación conceptual de familias FIS para diseño de sistemas de calidad del aire. Elaboración propia.

Reglas, funciones de pertenencia y defuzzificación El funcionamiento de un FIS puede leerse como una cadena de transformación de datos, desde una medición numérica hasta una salida de decisión. La Figura 2 resume esa cadena y permite ubicar con precisión el rol de reglas, funciones de pertenencia y defuzzificación (Andrianto y cols., 2024; Saleem y cols., 2024).




Figura 2. Flujo general de inferencia difusa para sistemas de calidad del aire. Elaboración propia.

La lectura técnica del flujo es la siguiente:

1. **Entradas crisp.** El sistema recibe variables numéricas medidas (por ejemplo, concentración de contaminantes, temperatura o humedad). Estas magnitudes están en unidades físicas y todavía no tienen significado lingüístico dentro del FIS.
2. **Fuzzificación.** Cada entrada x_j se transforma a grados de pertenencia mediante funciones $\mu_{A_{jk}}(x_j) \in [0, 1]$, donde A_{jk} representa etiquetas como *bajo*, *medio* o *alto*.

Esta etapa convierte una lectura puntual en una representación gradual, permitiendo modelar transiciones suaves entre estados (Olivas, 2003, 2019).

3. **Base de reglas.** El motor de inferencia evalúa reglas *if-then*; por ejemplo: “si PM2.5 es alto y humedad es alta, entonces riesgo es alto”. Cada regla obtiene una fuerza de activación α_r a partir de operadores difusos (t-norm/t-conorm), lo que cuantifica cuánto se cumple la condición antecedente (Olivas, 2003, 2019).
4. **Agregación.** Las salidas parciales de las reglas activadas se combinan en una única función de salida $\mu_{agg}(z)$. En Mamdani, esto suele hacerse con operaciones tipo máx y mín, preservando la contribución conjunta de todas las reglas relevantes.
5. **Defuzzificación.** La salida difusa agregada se convierte en un valor crisp z^* para habilitar decisión operativa (clasificación, control o alerta). El método más común es el centroide, que entrega un punto representativo del área de salida.

En términos de implementación, este encadenamiento conserva interpretación semántica en las etapas intermedias y, al mismo tiempo, entrega un resultado numérico operativo al final (Andrianto y cols., 2024; Saleem y cols., 2024). Esto es particularmente útil en monitoreo de calidad del aire, donde se necesita trazabilidad de la decisión y respuesta cuantificable.




Figura 3. Representación de funciones de pertenencia y números borrosos en un FIS. Elaboración propia.

La Figura 3a muestra cómo se construye la semántica de entrada en un FIS. El eje horizontal representa el universo de la variable (PM2.5), y el eje vertical el grado de pertenencia. Las funciones trapezoidales en extremos (*bajo*, *alto*) modelan zonas de saturación, mientras que la triangular central (*medio*) enfatiza una región de transición. La superposición entre curvas es intencional: una misma medición puede activar más de una etiqueta con distinta intensidad, evitando discontinuidades cuando el valor cruza umbrales.

La Figura 3b detalla el número borroso y su corte alfa. El número borroso se expresa como una función de pertenencia (triangular o trapezoidal), y el corte α selecciona todos los

valores del universo cuyo grado de pertenencia cumple $\mu(x) \geq \alpha$. Ese intervalo permite pasar de una descripción difusa a bandas numéricas con interpretación operativa, por ejemplo para fijar márgenes de decisión o niveles de incertidumbre (Zadeh, 1973; Olivas, 2003, 2019).




Figura 4. Comparación de salida en Mamdani (centroide) y Sugeno/TSK (promedio ponderado).
Elaboración propia.

La Figura 4 contrasta dos formas de obtener la salida crisp. En el panel A (Mamdani), cada regla produce una salida recortada, las salidas se agregan en una envolvente difusa y el valor final se calcula por centroide. Ese valor se obtiene como centro de masa de la salida agregada:

$$z^* = \frac{\int z \mu_{agg}(z) dz}{\int \mu_{agg}(z) dz}. \quad (4)$$

En el panel B (Sugeno/TSK), cada regla entrega un consecuente numérico z_r y la salida se obtiene mediante promedio ponderado por niveles de activación:

$$z^* = \frac{\sum_r \alpha_r z_r}{\sum_r \alpha_r}. \quad (5)$$

Esta diferencia es clave: Mamdani conserva interpretación lingüística hasta la agregación final, mientras que Sugeno/TSK opera directamente con consecuentes numéricos y reduce costo de inferencia (Zadeh, 1973; Andrianto y cols., 2024; Saleem y cols., 2024; Olivas, 2019). En ambos casos, la etapa final transforma la inferencia difusa en un valor operativo para clasificación, control o alerta.




Figura 5. Elementos estructurales e interpretación funcional de ANFIS. Elaboración propia.

La Figura 5a muestra la arquitectura interna típica de ANFIS. La Capa 1 calcula pertenencias de las entradas; la Capa 2 combina esas pertenencias para obtener la fuerza de activación de cada regla; la Capa 3 normaliza los pesos relativos; la Capa 4 evalúa el consecuente de cada regla como función lineal; y la Capa 5 integra todas las contribuciones en una salida única. Esta descomposición explica por qué ANFIS conserva semántica difusa en la premisa y, al mismo tiempo, se ajusta con parámetros entrenables sobre datos (Seibert y cols., 2024; Kowalski y cols., 2026; Erfianto y Rahmatsyah, 2022).

La Figura 5b representa la salida final como superficie en función de dos entradas. En práctica, esta superficie resume el comportamiento conjunto de todas las reglas después del entrenamiento: zonas planas indican sensibilidad baja, mientras que regiones con mayor pendiente reflejan cambios más rápidos de la salida frente a variaciones de entrada. Esta lectura es útil para verificar estabilidad, interpretar rangos operativos y detectar transiciones críticas en sistemas de calidad del aire (Kowalski y cols., 2026; Saini y cols., 2022b; Erfianto y Rahmatsyah, 2022; Olivas, 2019).

La comparación técnica permite fijar un criterio operativo para la propuesta. Mamdani es adecuado cuando la prioridad es trazabilidad de reglas y lectura directa de niveles de riesgo; Sugeno/TSK es conveniente cuando se requiere inferencia rápida con salida numérica estable en tiempo de ejecución; y ANFIS aporta capacidad de ajuste a partir de datos cuando el objetivo incluye estimación/predicción con variabilidad temporal (Zadeh, 1973; Seibert y cols., 2024; Andrianto y cols., 2024; Kowalski y cols., 2026; Erfianto y Rahmatsyah, 2022). Con base en ello, un diseño consistente para calidad del aire puede separar funciones: núcleo de decisión interpretable con reglas difusas explícitas y módulo de ajuste/predicción entrenable para mejorar respuesta cuantitativa sin perder auditabilidad del sistema.

4.3. Modelos de Regresión Supervisada

En aprendizaje supervisado, la regresión se utiliza cuando la variable objetivo es continua. El modelo aprende una función $f(\mathbf{x})$ que aproxima la relación entre predictores y salida numérica, a partir de ejemplos etiquetados $(\mathbf{x}_i, y_i)$ (Geron, 2023). Esta formulación es coherente con tareas como predicción de concentración de contaminantes o estimación de un índice continuo de calidad del aire.

Dentro de este marco, las familias de modelos se diferencian por el tipo de relación que pueden representar, el costo de entrenamiento y el nivel de interpretación disponible (Geron, 2023). En términos prácticos:

1. **Modelos lineales.** Suponen una relación aproximadamente lineal entre predictores y salida, del tipo $\hat{y} = \mathbf{w}^T \mathbf{x} + b$. Son útiles como línea base por su bajo costo computacional y alta interpretabilidad de coeficientes. Su principal límite aparece cuando la dinámica real es no lineal o presenta interacciones complejas entre variables.
2. **Árboles de decisión y ensambles.** Los árboles particionan el espacio de entrada por reglas secuenciales y capturan no linealidades sin requerir escalado estricto de variables. Ensamblados como *Random Forest* o *Gradient Boosting* reducen varianza o sesgo respecto a un árbol único y suelen mejorar robustez predictiva. El costo es menor interpretabilidad global y mayor complejidad de ajuste de hiperparámetros.
3. **Máquinas de soporte para regresión (SVR).** Buscan una función con buen margen y control explícito de complejidad, con posibilidad de mapear relaciones no lineales mediante kernels. Son efectivas en conjuntos de tamaño medio y con fronteras funcionales bien estructuradas. Su limitación práctica es la sensibilidad a parámetros del kernel y a la escala de variables.
4. **Redes neuronales.** Modelan relaciones altamente no lineales mediante composiciones de capas y activaciones, y pueden aproximar comportamientos complejos en escenarios multivariados. Son convenientes cuando existe volumen suficiente de datos y se prioriza capacidad predictiva. A cambio, requieren mayor costo de entrenamiento, regularización cuidadosa y validación estricta para evitar sobreajuste.

La selección no se basa en preferencia algorítmica aislada, sino en la coherencia entre complejidad del fenómeno, disponibilidad de datos, requisitos de tiempo de inferencia y necesidad de trazabilidad del modelo en el entorno de aplicación.

Para tomar una decisión, cuando la prioridad es interpretabilidad y trazabilidad, se favorecen modelos lineales o árboles de baja profundidad, porque permiten explicar con claridad el efecto de cada variable. Cuando la prioridad es precisión predictiva en patrones no lineales, suelen ser más competitivos los ensambles y las redes neuronales, asumiendo

mayor costo de ajuste y menor transparencia global. Para contextos operativos de calidad del aire, una práctica sólida consiste en comenzar con una base interpretable y escalar a modelos más complejos solo si la mejora de desempeño justifica la pérdida relativa de explicabilidad.

Las métricas centrales para regresión son MAE, MSE/RMSE, MAPE y R^2 , pero su utilidad depende del tipo de salida, la escala de los datos y el objetivo operativo de la predicción (Geron, 2023). Su interpretación técnica puede resumirse así:

1. **MAE (Error Absoluto Medio).** Mide error promedio en unidades originales de la variable objetivo. Es robusto frente a valores atípicos extremos en comparación con métricas cuadráticas y resulta útil cuando se busca una lectura directa del error esperado en operación.
2. **MSE/RMSE (Error Cuadrático Medio / Raíz del Error Cuadrático Medio).** Penalizan con mayor peso los errores grandes. Son adecuados cuando el costo de fallos severos es alto, por ejemplo sobreestimaciones o subestimaciones amplias en pronóstico de concentración.
3. **MAPE (Error Porcentual Absoluto Medio).** Expresa error relativo en porcentaje, lo que facilita comparar magnitudes entre series con escalas diferentes. Su uso exige cautela cuando los valores reales son cercanos a cero, porque puede inflar artificialmente el error porcentual.
4. **R^2 (Coeficiente de determinación).** Resume proporción de variabilidad explicada por el modelo respecto a una referencia base. Es útil como indicador de ajuste global, pero no sustituye métricas de error absoluto para evaluación operativa.

En aplicaciones de calidad del aire, una práctica metodológica sólida es reportar al menos una métrica de error absoluto (MAE o RMSE) y una de ajuste global (R^2), añadiendo MAPE cuando la escala de la variable permita una lectura porcentual estable. Esto mejora comparabilidad y evita conclusiones basadas en un único indicador.

Como contraste conceptual, el aprendizaje por refuerzo optimiza políticas de decisión secuencial mediante recompensas y no modela directamente una variable objetivo continua en formato supervisado estándar (Sutton y Barto, 2018). En esta investigación, el desarrollo de modelos predictivos queda fuera del alcance, porque la propuesta se concentra en evaluación actual del riesgo, inferencia explicable y alertamiento operativo sobre datos abiertos. Aun así, estas métricas y protocolos mantienen valor como base metodológica para una fase posterior en la que el motor de inferencia implementado pueda utilizarse para generar series derivadas, etiquetas de riesgo o nuevas salidas supervisadas que habiliten el entrenamiento de modelos predictivos de calidad del aire sobre datasets contruidos a partir del comportamiento del propio sistema.

Para asegurar comparabilidad según tipo de salida, se distinguen cuatro escenarios metodológicos:

1. **Predicción/estimación continua de contaminantes o índice.** La comparación válida se realiza con métricas de regresión (MAE, RMSE, MAPE, R^2), manteniendo la misma unidad física y el mismo horizonte temporal de predicción.
2. **Clasificación de estados o categorías AQI/IAQ.** La lectura debe basarse en métricas de clasificación (por ejemplo, exactitud, precisión, sensibilidad, F1 y matriz de confusión), porque el objetivo es asignar clases y no estimar magnitudes continuas.
3. **Clasificación con actuación o alertamiento.** Además del acierto de clase, la evaluación debe incluir desempeño operativo (latencia de inferencia, falsas alarmas y omisiones de alerta), ya que la utilidad final depende de la respuesta en campo.
4. **Pronóstico en series temporales por horizonte.** Cuando existe predicción a distintos horizontes, el error debe reportarse por tramo de anticipación (corto, medio, largo), evitando promedios únicos que oculten degradación a horizontes extensos.

Con estas reglas, la comparación entre estudios requiere tres condiciones simultáneas: misma unidad de salida evaluable, mismo protocolo de validación y métricas compatibles con dicha salida. Si alguna de estas condiciones no se cumple, el contraste cuantitativo pierde validez interpretativa.

Como cierre metodológico, la evaluación de la propuesta debe definirse desde el tipo de salida que se desea validar: si el objetivo principal es predicción/estimación continua, el bloque central de evaluación debe estructurarse con MAE/RMSE/ R^2 y análisis por horizonte; si el objetivo incluye clasificación de niveles o alertamiento, debe añadirse desempeño por clase y evidencia operativa de respuesta. Esta estructura permite que los resultados sean técnicamente auditables, comparables con antecedentes afines y útiles para decisiones de implementación en contexto real.

4.4. Datasets Públicos de Calidad del Aire

En esta investigación, los datasets públicos se consideran un componente estructural del diseño experimental, a partir de los que se alimentará el sistema difuso propuesto. Su función en el marco teórico es doble: sostener reproducibilidad de resultados y habilitar comparación técnica entre estudios con objetivos similares (Saini y cols., 2022b; Saini, Dutta, y Marques, 2022a; Behal y Singh, 2021; Kowalski y cols., 2026; Haidar y cols., 2025). Desde esa perspectiva, la lectura de fuentes públicas debe separar con claridad tres perfiles: plataformas actualizables, repositorios históricos curados y artefactos de proyecto publicados para replicación.

Las plataformas actualizables, como *OpenAQ*, aportan cobertura geográfica amplia, trazabilidad por estación y acceso programático para consulta de series históricas y ventanas recientes (OpenAQ, 2026). Su valor metodológico es que permiten construir flujos de ingestión y evaluación sobre datos que evolucionan en el tiempo, más cercanos a un escenario operativo. En ese mismo perfil, los portales nacionales de AQI usados en algunos antecedentes, como CPCB en India, ofrecen continuidad institucional de publicación, aunque con diferencias normativas y de estructura frente a otras fuentes (Haidar y cols., 2025).

Los repositorios históricos curados responden a otra necesidad: controlar mejor las condiciones de entrenamiento y validación. El conjunto *Air Quality* de UCI (ID 360) concentra una serie temporal horaria con canales de sensores químicos, variables meteorológicas y valores de referencia para tareas de modelado y calibración (Vito, 2008). En esa misma línea, el conjunto *Beijing Multi-Site Air Quality* (UCI ID 501) extiende la evaluación a múltiples estaciones y periodos, lo cual favorece análisis por sitio, particiones temporales y pruebas de transferencia entre contextos (Chen, 2017; Saini y cols., 2022b).

Un tercer grupo corresponde a artefactos abiertos asociados a estudios concretos. Aquí se ubican repositorios como *GAMS Indoor Air Quality Dataset*, colecciones heterogéneas UCI/Kaggle empleadas en marcos multipaís y conjuntos publicados en Zenodo con insumos de datos y modelos (Saini y cols., 2022a; Behal y Singh, 2021; Kowalski y cols., 2026). Estos recursos son valiosos para replicar decisiones de preprocesamiento y comparar pipelines, pero suelen reflejar el contexto específico del estudio que los publica, por lo que requieren mayor cautela para extrapolar resultados.

La principal implicación metodológica es que “dataset público” no equivale automáticamente a “dataset comparable”. Cambian la cobertura de contaminantes, las unidades de reporte, la resolución temporal, la proporción de valores faltantes y los criterios de control de calidad. Si estas diferencias no se normalizan y documentan, la comparación entre modelos mezcla efectos del método con efectos de la fuente de datos.

Por ello, para esta propuesta se exige trazabilidad mínima en cada fuente: origen institucional, licencia de uso, variables seleccionadas, ventana temporal efectiva, resolución de muestreo, reglas de limpieza e imputación, y protocolo de partición/validación. Esta trazabilidad reduce el riesgo de sobreestimar rendimiento en un entorno local y mejora la transferibilidad de los resultados hacia escenarios urbanos distintos.

La Tabla 2 resume las fuentes públicas priorizadas y su lectura metodológica para esta investigación.

Fuente pública	Tipo de acceso	Cobertura temporal y espacial	Variables típicas	Aporte metodológico	Riesgo o limitación clave
<i>OpenAQ</i> (OpenAQ, 2026)	Plataforma abierta con consulta programática	Multipaís; ventanas recientes e históricas según estación disponible	Concentraciones de contaminantes, metadatos de estación, coordenadas, tiempo de medición	Permite diseño de ingestión reproducible y evaluación en tiempo cuasi real con trazabilidad por punto de medición	Heterogeneidad entre países, cambios de disponibilidad por estación y diferencias de políticas de reporte
<i>Air Quality UCI</i> (ID 360) (Vito, 2008)	Repositorio académico curado (descarga fija)	Serie horaria en contexto urbano industrial; ventana histórica cerrada	Señales de sensores químicos, temperatura, humedad, variables auxiliares y valores de referencia	Facilita experimentación controlada, comparación de modelos y auditoría de pre-procesamiento	No refleja dinámica operacional actual; requiere manejo explícito de faltantes y deriva de sensores
<i>Beijing Multi-Site Air Quality UCI</i> (ID 501) (Chen, 2017; Saini y cols., 2022b)	Repositorio académico curado (descarga fija)	Múltiples estaciones y varios años, con variación espacial y temporal amplia	Contaminantes criterio, variables meteorológicas y marca de tiempo por estación	Soporta validación por sitio y por periodo, y pruebas de transferencia entre contextos urbanos	Diferencias entre estaciones y periodos pueden inducir sesgo si no se controla partición temporal/espacial
<i>GAMS Indoor Air Quality Dataset</i> (Saini y cols., 2022a)	Repositorio abierto asociado a estudio	Predominio indoor; cobertura ligada al alcance del despliegue reportado	Variables de calidad de aire interior y contexto ambiental del experimento	Útil para replicar pipelines en escenarios indoor y comparar decisiones de modelado en dominio acotado	Menor diversidad de contextos; generalización limitada fuera del entorno de captura
Colecciones públicas heterogéneas (AQD-IC, AQD-RM, AQD-GC, AQD-NT) (Behal y Singh, 2021)	Integración de UCI, Kaggle y portales institucionales	Cobertura multicontenido y multiorigen, con normas de reporte distintas	Variables de contaminantes y apoyo ambiental con formatos no homogéneos	Permite contrastar robustez de modelos frente a fuentes diversas	Alta carga de armonización semántica, unidades y calidad de datos antes de comparar desempeño

Continued on next page

(Continued)

Fuente pública	Tipo de acceso	Cobertura temporal y espacial	Variables típicas	Aporte metodológico	Riesgo o limitación clave
Portal nacional AQI (CPCB, India) (Haidar y cols., 2025)	Publicación institucional continua	Cobertura nacional por red oficial; actualización periódica del índice y/o variables de base	Índice AQI y componentes según política nacional	Sirve como referencia oficial para estimación/predicción en contexto regulatorio real	Comparabilidad internacional condicionada por norma local, umbrales y estructura de publicación
Artefactos abiertos en Zenodo (casos Calgary y Lima) (Kowalski y cols., 2026)	Publicación de datos y modelos de estudio	Conjuntos específicos por ciudad y periodo de campaña	Registros de co-localización LCS—estación de referencia y metadatos de experimento	Mejora trazabilidad de replicación y auditoría de resultados reportados	Cobertura focalizada en campañas concretas; transferibilidad depende de similitud con nuevas ciudades

Tabla 2. Síntesis comparativa de datasets públicos de calidad del aire utilizados como referencia metodológica. Elaboración propia.

A partir de esta síntesis, el análisis de limitaciones se reduce al tipo de sesgo que introduce en el ciclo de modelado. El sesgo de cobertura espacial aparece cuando el entrenamiento se concentra en pocas estaciones o en un solo contexto urbano; en ese caso, el modelo puede aprender patrones locales y perder estabilidad al transferirse a otra ciudad (Kowalski y cols., 2026; Saini y cols., 2022a). El sesgo temporal surge cuando la ventana de datos no incluye suficiente variación estacional o cambios operativos, lo que afecta especialmente tareas de predicción por horizonte y validación fuera de muestra (Saini y cols., 2022b; Chen, 2017).

También existe sesgo por instrumentación y protocolo de medición: distintas redes usan sensores, calibraciones y criterios de control de calidad diferentes, por lo que una misma variable puede no ser estrictamente equivalente entre fuentes (Behal y Singh, 2021; Kowalski y cols., 2026). A esto se suma el sesgo de completitud, asociado a valores faltantes, retrasos de publicación y revisiones posteriores de registros en plataformas actualizables, situación que puede alterar métricas si no se fija una política de corte temporal y depuración reproducible (OpenAQ, 2026). Finalmente, en fuentes basadas en índices nacionales, aparece sesgo normativo: cambian umbrales y categorías de interpretación, de modo que comparar resultados entre jurisdicciones exige armonizar primero la semántica del índice (Haidar y cols., 2025).

Por tanto, la validez metodológica depende de declarar explícitamente qué sesgos son tolerados, cuáles se corrigen y cuáles se controlan por diseño experimental. Sin esta declaración, un resultado puede parecer competitivo en métrica agregada y, al mismo tiempo, carecer de robustez cuando se desplaza a otro contexto geográfico, temporal o regulatorio.

Con esta base, la selección de datasets para la propuesta se define mediante criterios operativos verificables:

1. **Trazabilidad de origen.** La fuente debe identificar institución responsable, ubicación de medición, marca temporal y metadatos suficientes para auditoría.
2. **Cobertura de variables pertinente.** Debe incluir contaminantes y variables ambientales coherentes con la salida objetivo del modelo (clasificación o predicción de AQI/IAQ).
3. **Resolución temporal utilizable.** La frecuencia de muestreo debe permitir construir ventanas de entrada y horizontes de salida sin interpolaciones excesivas.
4. **Calidad y completitud.** Se requiere política explícita para faltantes, valores atípicos y consistencia de unidades antes de cualquier comparación de desempeño.
5. **Comparabilidad normativa.** Si se integran fuentes de distintas jurisdicciones, se debe armonizar la semántica de categorías y umbrales del índice.
6. **Reproducibilidad técnica.** El acceso a datos debe ser estable y replicable (consulta programática o descarga versionada), junto con documentación mínima de extracción.
7. **Potencial de validación externa.** La fuente debe permitir particiones por tiempo, sitio o contexto para evaluar transferencia y no solo ajuste local.

La regla de decisión derivada de estos criterios es usar una combinación de fuentes con roles complementarios: una fuente pública actualizable como base operativa del sistema, y una o más fuentes históricas curadas para pruebas controladas y validación de estabilidad. Esta combinación permite balancear realismo de despliegue, comparabilidad metodológica y robustez externa del desempeño reportado.

5. Desarrollo del Proyecto y Resultados

5.1. Planteamiento del Problema

La calidad del aire constituye un problema técnico, sanitario y de gestión pública cuya complejidad supera la mera medición puntual de contaminantes. La evidencia reciente muestra que la exposición prolongada a contaminantes atmosféricos sigue asociándose a una carga global elevada de enfermedad y mortalidad: distintos antecedentes reportan alrededor de siete millones de muertes a escala mundial vinculadas a la exposición prolongada a material particulado y otros contaminantes del aire (Saleem y cols., 2024, p. 1), mientras que otros trabajos sitúan en 4.2 millones las muertes prematuras asociadas a contaminación atmosférica exterior (Seibert y cols., 2024, p. 1). Esta magnitud confirma que el problema tiene impacto en la vigilancia ambiental y además exige mecanismos de evaluación y alerta que puedan traducir datos técnicos en decisiones funcionales oportunas para reducir exposición y riesgo.

Dentro de ese escenario, el índice de calidad del aire (AQI) se ha consolidado como uno de los principales instrumentos para interpretar el estado del aire y comunicarlo a autoridades y ciudadanía. Sin embargo, la literatura especializada también señala que persisten diferencias relevantes en contaminantes considerados, métodos de cálculo, escalas de agregación y criterios de interpretación entre modelos de AQI. La revisión crítica de modelos AQI desarrollados entre 1960 y 2021 concluye, de forma explícita, que todavía se requiere un modelo más confiable, extensible y comparable para apoyar programas estratégicos de abatimiento de la contaminación y preservar la salud pública (K y Kumar, 2022, p. 1). Esta necesidad se vuelve más evidente en contextos urbanos con alta presión ambiental; por ejemplo, en dicha revisión se reporta que Delhi registró en 2019 una concentración media diaria de $PM_{2.5}$ de $98.6 \mu g/m^3$, equivalente a diez veces la recomendación de la OMS (K y Kumar, 2022, p. 2). En consecuencia, el problema va más allá de captar datos; se evidencia la necesidad de convertirlos en evaluaciones consistentes, comparables y útiles para la toma de decisiones.

En respuesta a esta necesidad, los trabajos recientes han incorporado lógica difusa, IoT y arquitecturas distribuidas para clasificación, monitoreo y predicción de calidad del aire. No obstante, el análisis de antecedentes muestra que estos avances siguen siendo parciales y heterogéneos. Existen propuestas basadas en datasets abiertos que reconocen la necesidad de ampliar su validación a otras localizaciones para reducir sesgo geográfico (Seibert y cols., 2024, p. 7); otras implementaciones priorizan el monitoreo y control local, pero declaran que no generaron ni analizaron datasets para validar su

comportamiento de manera reproducible (Bushnag, 2023, p. 10); y trabajos centrados en redes WSN mejoran eficiencia de red, retardo o entrega de paquetes, pero concentran la optimización en la infraestructura de transmisión más que en la validación comparable de modelos predictivos sobre datos reutilizables (Lingaraj y cols., 2025, pp. 1,4). Esta diversidad confirma que el campo está activo, pero también que la trazabilidad del dato, la comparabilidad de evaluación y la transferencia de resultados entre contextos siguen siendo insuficientes.

La revisión sistemática desarrollada en este trabajo refuerza esa misma lectura. En el corpus analizado predominan estudios sustentados en adquisición directa por sensores, mientras la utilización exclusiva de datos públicos es excepcional; además, la mayor parte de las propuestas trabaja con conjuntos reducidos de contaminantes y con énfasis mayor en clasificación o alertamiento, no en predicción robusta y externamente comparable. Los estudios orientados a predicción, aunque técnicamente prometedores, continúan concentrados en escenarios acotados y con validaciones parciales. Por ejemplo, algunos trabajos combinan datos de pocos sitios urbanos y rurales con validación adicional sobre subconjuntos de datasets de referencia (Saini y cols., 2022b, pp. 3–4), (Saini y cols., 2022a, p. 2); otros reportan predicción a 24 horas, pero dentro de entornos interiores específicos (de Assis Pedrobon Ferreira, Grout, y da Silva, 2022, p. 1); y propuestas recientes con alto ajuste estadístico plantean como trabajo futuro la colaboración entre múltiples ciudades, lo que evidencia que la validación interurbana sigue sin resolverse de manera sólida (Haidar y cols., 2025, p. 5). En contraste, casos como (Kowalski y cols., 2026, p. 2) muestran el valor de entrenar y depurar modelos neuro-difusos sobre datos multi-localización del mundo real, pero este tipo de aproximación todavía no representa la práctica dominante.

En funciones metodológicas y de ingeniería, el problema central radica en la ausencia de una solución que integre, en un mismo marco reproducible, cuatro componentes que suelen aparecer desacoplados: una fuente de datos abiertos trazable y suficientemente robusta, un proceso de preparación y control de calidad de datos documentado, un núcleo de inferencia difusa auditable para interpretar riesgo, y una validación comparable que permita verificar estabilidad del desempeño fuera del contexto inicial. Cuando alguno de estos componentes falta, el resultado puede ser útil como prototipo local, pero no como base confiable para una solución transferible y reutilizable en otros escenarios urbanos.

Con base en ello, el problema que aborda esta investigación se define como la necesidad de un módulo de monitoreo de calidad del aire que, apoyado en datos abiertos de redes de monitoreo ambiental, permita evaluar riesgo y generar alertas mediante inferencia difusa bajo un esquema técnicamente trazable, reproducible y con capacidad de validación en escenarios urbanos. Esta formulación se alinea de manera directa con los objetivos del trabajo: caracterizar la evidencia disponible, diseñar una arquitectura funcional coherente con los vacíos detectados, implementar el módulo propuesto e introducir una validación

que considere la utilidad práctica del modelo como sistema de apoyo a la decisión.

5.2. Metodología

Enfoque y tipo de investigación

El presente trabajo se enmarca en una investigación aplicada orientada al desarrollo de una solución tecnológica para un problema real. El enfoque metodológico combina una revisión sistemática de la literatura, utilizada para fundamentar el problema y derivar criterios de diseño, y una lógica de investigación basada en diseño de artefacto, consistente con los principios de *Design Science Research*, donde el conocimiento se materializa mediante la definición, construcción y evaluación de una solución útil frente a una necesidad identificada (Hevner, March, Park, y Ram, 2004, pp. 75–77), (Peffer, Tuunanen, Rothenberger, y Chatterjee, 2008, pp. 46,55–56). La validación del módulo se formula como una evaluación empírica del artefacto centrada en la utilidad, la calidad y el desempeño de la solución desarrollada.

Diseño metodológico del estudio

El estudio se organiza en fases metodológicas claramente definidas para garantizar coherencia y trazabilidad entre los objetivos planteados y las actividades desarrolladas. La secuencia articula el proceso de revisión sistemática con la lógica propuesta por DSRM para investigación basada en diseño (Peffer y cols., 2008, pp. 46,71). La primera fase cumple la función de fundamentación y delimitación del problema. Las fases posteriores se orientan a la definición de la solución, la construcción del artefacto, su demostración funcional y su evaluación. Las fases del estudio son las siguientes:

1. Revisión sistemática del estado del arte.
2. Diseño del módulo de monitoreo.
3. Implementación del módulo propuesto.
4. Validación del módulo propuesto.

La relación con DSRM se utiliza aquí como marco de organización del estudio. La fase 1, basada en revisión sistemática, cumple la función de identificar y justificar el problema y aporta la base para definir los objetivos de la solución. La fase 2 corresponde a la definición de esos objetivos y al diseño conceptual del artefacto. La fase 3 corresponde a la construcción del artefacto e incorpora una demostración funcional inicial de su operabilidad. La fase 4 corresponde a la evaluación del módulo implementado. El paso de comunicación de DSRM se concreta en la memoria del TFM y en el manuscrito derivado de la revisión sistemática (Peffer y cols., 2008, pp. 51–56).

1: Revisión sistemática del estado del arte

La revisión sistemática constituye la primera fase metodológica del TFM. Su función fue identificar el problema, caracterizar el estado del arte reciente y derivar criterios de diseño para el artefacto desarrollado en las fases posteriores. Aunque la revisión forma parte del presente trabajo, su desarrollo completo se consolidó en un manuscrito independiente enviado a evaluación. En esta memoria se conserva únicamente el nivel de detalle necesario para explicar su papel metodológico; la síntesis de hallazgos resultantes se presenta en el Capítulo 3.

El protocolo de revisión se estructuró mediante el modelo PICO y la guía PRISMA 2020 (Page y cols., 2021), siguiendo además las recomendaciones de Kitchenham para revisiones en ingeniería de software y sistemas (Kitchenham y Charters, 2007). La delimitación PICO permitió definir con precisión el fenómeno de interés, el enfoque metodológico y el contexto de aplicación, manteniendo consistencia con el problema del TFM.

Compo- nente	Término resumido	Descripción operativa
P	Calidad del aire urbano	Evaluada a partir de concentraciones de contaminantes atmosféricos (por ejemplo, $PM_{2,5}$, PM_{10} , NO_2 , O_3) y variables ambientales asociadas, utilizadas como indicadores del estado de la calidad del aire.
I	Lógica difusa para evaluación ambiental	Aplicación de sistemas de inferencia basados en lógica difusa (por ejemplo, Mamdani o Sugeno) para la evaluación del nivel de calidad del aire y del riesgo asociado, mediante reglas lingüísticas y funciones de pertenencia.
Co	Monitoreo en tiempo real	Plataformas y sistemas de monitoreo en tiempo real orientados al análisis y visualización de datos de calidad del aire, provenientes de sensores ambientales y/o fuentes de datos abiertas.

Tabla 3. Marco PICO utilizado para la revisión del estado del arte. Elaboración propia.

A partir de esta delimitación se formuló la pregunta de revisión: ¿cómo se utilizan los sistemas de inferencia basados en lógica difusa en plataformas de monitoreo en tiempo real para evaluar la calidad del aire urbano y los riesgos asociados? Esta pregunta se operacionalizó mediante tres directrices analíticas: variables y contaminantes utilizados, criterios de diseño de los modelos difusos y características de las plataformas de monitoreo en tiempo real.

La búsqueda bibliográfica se ejecutó en Scopus, Web of Science e IEEE Xplore. Se restringió a publicaciones en inglés entre 2021 y 2026 y a documentos arbitrados con relación directa con monitoreo de calidad del aire, lógica difusa y operación en tiempo real. La construcción de la cadena de búsqueda siguió la estructura PICO y combinó

términos del dominio atmosférico, del enfoque difuso y del contexto de plataforma mediante bloques lógicos equivalentes entre bases. El objetivo de esta fase fue recuperar un conjunto suficientemente amplio para caracterizar el campo, pero lo bastante acotado para sostener una evaluación detallada y trazable.

La selección de estudios siguió el flujo PRISMA 2020, con fases de identificación, depuración de duplicados, cribado por título y resumen, recuperación de texto completo, elegibilidad e inclusión final. La elegibilidad se definió con base en la relación efectiva del estudio con tres dimensiones: datos y variables de calidad del aire, uso central de lógica difusa y presencia de plataforma o sistema de monitoreo. El corpus final quedó constituido por 19 estudios primarios. Los artefactos metodológicos y de respaldo de esta fase se consolidaron en el manuscrito del SLR y en su repositorio asociado.

Evaluación de Calidad

La evaluación de calidad se diseñó para valorar la solidez metodológica de los estudios incluidos y para apoyar la interpretación posterior de la evidencia. El instrumento se construyó a partir del bloque cuantitativo propuesto por Kitchenham (Kitchenham y Charters, 2007), seleccionando únicamente ítems pertinentes para la pregunta de revisión, el tipo de evidencia reportada y el dominio analizado. El resultado fue un checklist de 30 ítems, organizado en un núcleo común y componentes específicos según subtipo de estudio cuantitativo.

Cada estudio se clasificó previamente según su naturaleza metodológica y se evaluó únicamente con los ítems aplicables. La codificación utilizó las categorías Yes, Partial, No, Unclear y N/A, con respaldo por página para cada decisión. La puntuación agregada se empleó para distinguir evidencia de calidad alta, media o baja, pero no como criterio de exclusión automática. Su función fue orientar la lectura crítica de los hallazgos y detectar posibles sesgos de diseño, ejecución, análisis o reporte.

Extracción de datos

La extracción de datos se definió antes del análisis y se orientó a responder de forma directa la pregunta principal y las tres directrices de la revisión. La matriz final integró metadatos bibliográficos, variables y contaminantes, características del enfoque difuso, arquitectura y operación de plataforma, resultados reportados y trazabilidad metodológica. Antes de la extracción definitiva se realizó un piloto para estabilizar definiciones operacionales, reducir ambigüedad semántica y eliminar campos redundantes. Como resultado de ese ajuste, la matriz final quedó estructurada en 48 columnas analíticas.

La extracción se ejecutó artículo por artículo, con un catálogo controlado para variables categóricas y con registro explícito de evidencia por página para cada afirmación analítica. Esta decisión permitió mantener una relación verificable entre síntesis e información de origen. La consistencia de la matriz se comprobó mediante controles estructurales,

normalización semántica y auditoría cruzada contra los PDFs de los estudios incluidos.

Análisis y Síntesis de Datos

El análisis se desarrolló en una secuencia de preparación, descripción, identificación de patrones, construcción de perfiles e integración narrativa. En la fase de preparación se normalizaron categorías y se consolidó la matriz de extracción. En la fase descriptiva se calcularon frecuencias y distribuciones por dimensión analítica. En la fase relacional se emplearon tablas cruzadas y matrices de coocurrencia para identificar configuraciones recurrentes entre variables, modelos difusos y plataformas. Posteriormente, estos patrones se sintetizaron en perfiles comparables de diseño y operación.

La implementación analítica se realizó con Python, principalmente mediante *pandas*, *matplotlib* y *seaborn*. Este flujo permitió mantener consistencia entre procesamiento, visualización y redacción de resultados. La salida sustantiva de esta fase se recoge en el Capítulo 3, donde se presentan los hallazgos del estado del arte y sus implicaciones para el diseño del módulo propuesto.

2: Diseño del módulo de monitoreo

Esta fase se inscribe en el segundo paso de DSRM, *define the objectives of a solution*, y recoge además la parte inicial del tercer paso, *design and development*, en lo relativo a la formulación conceptual del artefacto (Peppers y cols., 2008, pp. 52–55). Su función es establecer, con base en la fase 1, qué debe resolver el módulo y bajo qué condiciones debe hacerlo. Esta fase convierte los hallazgos del estado del arte en requisitos explícitos de solución.

El trabajo de diseño se desarrolla sobre cuatro decisiones principales:

1. **Delimitación del alcance funcional del módulo.** En esta decisión se distinguen las funciones que forman parte del artefacto: adquisición de datos, consolidación del estado de calidad del aire, evaluación difusa del riesgo y generación de alertas.
2. **Definición del flujo lógico de procesamiento.** En este punto se identifica el recorrido de los datos desde la fuente de entrada hasta la salida final y se fijan los puntos donde el sistema debe conservar trazabilidad documental.
3. **Precisión de la estructura de entradas y salidas.** Esta decisión incluye la definición de contaminantes, covariables, variables derivadas y categorías de riesgo que deberán integrarse en el módulo.
4. **Selección del esquema de inferencia y de los criterios de diseño.** Aquí se determina el tipo de inferencia difusa y las condiciones de diseño del artefacto, de modo que la propuesta responda al objetivo del TFM y a los vacíos identificados en comparabilidad, auditabilidad e integración operativa.

Como producto de esta fase se obtiene una especificación de diseño. Esa especificación debe dejar definidos el alcance del artefacto, la arquitectura funcional, el papel de la fuente de datos, el criterio de construcción de la salida y las condiciones que guiarán la implementación y la validación posterior. Su función dentro del estudio es reducir ambigüedad entre la evidencia revisada y el desarrollo técnico del módulo (Hevner y cols., 2004, pp. 84–85).

3: Implementación del módulo propuesto

Esta fase desarrolla el núcleo del tercer paso de DSRM, *design and development*, y enlaza con el cuarto paso, *demonstration*, mediante una verificación funcional inicial del artefacto (Peppers y cols., 2008, pp. 55–56). Su función es convertir la especificación definida en la fase 2 en un módulo ejecutable. En esta etapa se construyen e integran los componentes del sistema bajo un criterio de continuidad operativa y reproducibilidad técnica.

La implementación comprende las siguientes tareas:

1. **Selección y configuración de tecnologías de soporte.** Esta tarea fija la base técnica sobre la que se ejecutará el módulo.
2. **Construcción del mecanismo de adquisición y preparación de datos.** Aquí se implementan las funciones de consulta, transformación, control de calidad y estructuración de la entrada.
3. **Codificación del núcleo de inferencia.** En esta tarea se materializan las variables, reglas y salidas del componente difuso.
4. **Integración del flujo completo de ejecución.** En este punto se enlazan adquisición, procesamiento, inferencia y salida dentro de un único recorrido funcional.
5. **Definición de reglas operativas de ejecución.** Esta tarea incluye tratamiento de errores, registro de metadatos y trazabilidad de la ejecución.

El objetivo metodológico de la fase es disponer de un artefacto funcional cuya ejecución pueda repetirse bajo las mismas condiciones y con resultados consistentes.

La demostración funcional se ubica al cierre de esta fase. Su propósito es comprobar que el módulo ejecuta el recorrido completo previsto en el diseño, desde la recuperación de datos hasta la emisión de una salida interpretable. Esta demostración no sustituye la evaluación formal, pero aporta evidencia de factibilidad técnica y permite identificar fallos de integración antes de la fase de validación (Hevner y cols., 2004, p. 85).

4: Validación del módulo propuesto

Esta fase corresponde al quinto paso de DSRM, *evaluation* (Peppers y cols., 2008, p. 56). Su propósito es determinar si el módulo satisface los objetivos fijados en la fase 2 y si su comportamiento resulta útil, consistente y técnicamente adecuado para el problema abordado. La validación se organiza como una evaluación empírica del artefacto, orientada a comprobar el comportamiento del sistema bajo condiciones de uso definidas de antemano.

La evaluación se estructura mediante escenarios representativos del funcionamiento esperado del módulo:

1. **Condiciones nominales de operación.** Se comprueba el comportamiento del sistema cuando los datos se encuentran dentro de rangos esperados.
2. **Situaciones cercanas o superiores a umbrales de alerta.** Se verifica la coherencia entre las condiciones observadas y la respuesta de riesgo emitida por el módulo.
3. **Casos con variaciones en completitud o calidad del dato.** Se observa la estabilidad del sistema ante faltantes, cobertura parcial o disponibilidad incompleta de contaminantes.

Cada escenario se ejecuta sobre una ventana temporal explícita y con documentación de la fuente utilizada, de la cobertura efectiva de datos y de las reglas de selección del conjunto evaluado. Este procedimiento es necesario porque la propuesta depende de datos abiertos y, por tanto, la validez de la evaluación depende tanto del motor difuso como de la calidad y trazabilidad de la entrada.

La validación considera cuatro dimensiones de análisis:

1. **Completitud funcional del pipeline.** Se verifica la capacidad del sistema para recorrer todas sus etapas y producir una salida.
2. **Coherencia entre condiciones observadas y respuesta del módulo.** Se analiza la correspondencia entre la entrada y la clasificación o alerta emitida.
3. **Desempeño operativo.** Se registra el tiempo de respuesta y la estabilidad básica de ejecución.
4. **Reproducibilidad.** Se comprueba la estabilidad de la salida cuando se repiten las mismas condiciones de entrada y procesamiento.

El resultado esperado de esta fase es una base empírica suficiente para juzgar el comportamiento del artefacto e introducir ajustes cuando sea necesario (Hevner y cols., 2004, pp. 86–87).

Consideraciones finales de la metodología

La secuencia metodológica del TFM se organizó mediante una planificación temporal por fases, articulando revisión sistemática, diseño del módulo, implementación, validación y redacción final. La Figura 6 resume esta organización entre mediados de octubre de 2025 y mediados de abril de 2026, identificando la duración relativa de cada bloque, sus solapes principales y los hitos del proceso.




Figura 6. Roadmap temporal del TFM por fases, actividades e hitos principales. Elaboración propia.

Este esquema cumple una función metodológica de trazabilidad. Sitúa cada fase dentro del desarrollo global del trabajo, identifica dependencias entre actividades y hace visible la superposición parcial entre síntesis, diseño, construcción y cierre documental. En el tramo final del estudio, esta planificación también sirve como base para interpretar el alcance efectivo del trabajo, sus limitaciones y las extensiones posibles del módulo propuesto.

5.3. Desarrollo del Proyecto

Propuesta del módulo

La propuesta técnica del TFM se materializó en un prototipo ejecutable denominado *AQRisk*. El artefacto implementa un módulo híbrido para monitoreo de calidad del aire, evaluación de riesgo y generación de alertas sobre datos abiertos. Su diseño conserva una base normativa explícita para el cálculo del estado del aire y añade una capa de inferencia difusa para ajustar la severidad operativa del episodio.

La decisión central del diseño fue separar dos problemas. El primero consiste en conso-

lidar el estado base del aire con una referencia regulatoria trazable. El segundo consiste en interpretar ese estado cuando aparecen concurrencia entre contaminantes, persistencia temporal o condiciones ambientales de contexto. Esta separación mantiene comparabilidad externa y deja trazable el aporte del módulo en la parte de interpretación y alertamiento.

Arquitectura funcional del módulo

El prototipo implementado se organiza en cinco capas funcionales encadenadas. La Figura 7 resume esta arquitectura.

Arquitectura funcional implementada del modulo AQRisk




Figura 7. Arquitectura funcional implementada del módulo AQRisk. Elaboración propia.

1. **Consolidación normativa.** Recupera las series horarias, calcula subíndices por contaminante y consolida el AQI global.
2. **Variables auxiliares.** Deriva persistencia temporal y concurrencia multi-contaminante a partir del estado base calculado.
3. **Inferencia difusa principal.** Aplica la base principal de 54 reglas sobre AQI base, concurrencia y persistencia.
4. **Capa contextual basada en reglas.** Modula la salida principal mediante temperatura y humedad cuando esas variables están disponibles y el episodio ya se encuentra comprometido.

5. **Alertamiento y salida.** Genera la clasificación final, compone la alerta interpretable y serializa el resultado en formato JSON.

La arquitectura por capas aporta explicabilidad técnica. Cada bloque resuelve una función específica y conserva trazabilidad del paso anterior. Esta organización facilita la verificación del comportamiento del sistema y evita mezclar cálculo normativo, lógica difusa y composición de la salida dentro de una sola etapa.

Arquitectura de software y flujo de ejecución

La implementación se realizó en Python mediante una arquitectura modular monoproceso. La estructura del paquete separa modelos de dominio, ingesta, procesamiento, cálculo AQI, motor difuso, alertamiento, orquestación e interfaz de línea de comandos. Esta decisión reduce complejidad accidental y deja preparada una migración posterior a servicios independientes si el trabajo la requiere.

El flujo de ejecución del prototipo se presenta en la Figura 8.




Figura 8. Flujo de ejecución del prototipo implementado. Elaboración propia.

El pipeline resuelve la configuración de ejecución, consulta sensores por *location_id*, recupera series horarias recientes, normaliza datos, calcula cobertura, construye el AQI base, deriva concurrencia y persistencia, ejecuta el motor difuso, aplica la capa contextual cuando corresponde y genera una salida JSON trazable. Esta salida está preparada para exponer el módulo por CLI, por contenedor Docker y, en una etapa posterior, por API o interfaz web.

Fuente de datos, variables y criterios normativos

La fuente operativa principal del prototipo es *OpenAQ*, utilizada como plataforma abierta de consulta programática de mediciones y metadatos de estaciones (OpenAQ, 2026). El módulo recupera mediciones por estación, sensor y ventana temporal. La fuente se usa como repositorio de observaciones y no como proveedor de un índice final ya resuelto.

La capa normativa del módulo se apoya de forma explícita en la tabla vigente de *AQI Breakpoints* de *EPA/AQS* (United States Environmental Protection Agency, 2026). A partir de esa referencia se implementaron los contaminantes criterio $PM_{2,5}$, PM_{10} , CO, NO_2 , O_3 y SO_2 , junto con sus ventanas regulatorias y categorías del índice. La versión actual del prototipo utiliza:

1. $PM_{2,5}$ con promedio de 24 horas.
2. PM_{10} con promedio de 24 horas.
3. CO con promedio de 8 horas.
4. NO_2 con valor horario.
5. O_3 con comparación entre ventanas de 8 horas y 1 hora, según tramo aplicable.
6. SO_2 con comparación entre valor horario y promedio de 24 horas.

El tratamiento de ventanas parciales se resuelve mediante un umbral mínimo de cobertura del 80 %. Cuando la ventana no está completa, el módulo admite cálculo si la cobertura supera ese umbral y deja registro de la condición aplicada. Esta decisión conserva utilidad operativa sobre datos abiertos sin ocultar la completitud efectiva de la serie.

El prototipo admite además temperatura y humedad como variables de contexto. Estas variables no participan en la consolidación del AQI y tampoco sustituyen a los contaminantes criterio. Su función es modular la salida del riesgo cuando ya existe un episodio comprometido. La variable CO_2 no se incorporó al núcleo porque su uso en los antecedentes revisados se concentra en calidad de aire interior y escenarios IAQ, no en el núcleo regulatorio urbano (Saini y cols., 2022b; Istiqomah y cols., 2021; Zareb y cols., 2021).

Sobre esa base, el módulo deriva las siguientes variables internas:

- **AQI global**, como estado base consolidado.
- **Contaminante dominante**, para identificar la variable que gobierna el episodio.
- **Persistencia temporal**, calculada sobre estados AQI sucesivos del propio módulo.
- **Concurrencia**, definida como cercanía entre varios subíndices respecto del dominante.
- **Cobertura global**, como indicador de completitud de la entrada efectiva.

La salida final del prototipo conserva la taxonomía EPA: *Good*, *Moderate*, *Unhealthy for Sensitive Groups*, *Unhealthy*, *Very Unhealthy* y *Hazardous*. El resultado se expresa junto con la alerta textual, el AQI base y la lista de reglas activadas.

Transición entre capas y variables derivadas

La transición entre la capa normativa y la capa de interpretación se resuelve mediante una secuencia explícita de derivaciones. Primero, cada contaminante criterio se transforma en un subíndice AQI con *breakpoints* EPA/AQS. Para cada contaminante p , la formulación implementada sigue:

$$I_p = \frac{I_{Hi} - I_{Lo}}{BP_{Hi} - BP_{Lo}} (C_p - BP_{Lo}) + I_{Lo}, \quad (6)$$

donde C_p es la concentración representativa del contaminante en la ventana regulatoria aplicable, BP_{Lo} y BP_{Hi} son los *breakpoints* del tramo, e I_{Lo} e I_{Hi} son los límites del subíndice en ese tramo (United States Environmental Protection Agency, 2026). En el prototipo, las concentraciones representativas se obtienen con ventanas diferenciadas: 24 h para $PM_{2,5}$ y PM_{10} , 8 h para CO, valor horario para NO_2 , comparación entre 8 h y 1 h para O_3 , y comparación entre 1 h y 24 h para SO_2 .

Una vez calculados los subíndices, el estado base del episodio queda determinado por el contaminante dominante:

$$AQI_{global} = \max(I_{pm25}, I_{pm10}, I_{co}, I_{no2}, I_{o3}, I_{so2}). \quad (7)$$

El contaminante asociado a ese máximo se registra como dominante y pasa a gobernar la categoría base del episodio.

Sobre ese estado base, el prototipo deriva dos variables auxiliares antes de entrar al motor *Mamdani*. La primera es la concurrencia multi-contaminante. Para calcularla se fija un umbral de cercanía respecto del dominante:

$$threshold = \max(25, 0,8 \cdot AQI_{dominante}). \quad (8)$$

Luego, para cada contaminante adicional i , se define una cercanía normalizada:

$$closeness_i = clamp\left(\frac{AQI_i - threshold}{AQI_{dominante} - threshold}, 0, 1\right). \quad (9)$$

La puntuación final de concurrencia queda dada por:

$$concurrence = \min\left(100, \frac{\sum_i closeness_i}{3} \cdot 100\right). \quad (10)$$

Esta formulación conserva una escala de 0 a 100 y resume cuántos contaminantes adicionales quedan realmente cerca del dominante, sin introducirlos como entradas independientes de la malla principal.

La segunda variable auxiliar es la persistencia temporal. El prototipo construye una historia corta de estados base del propio módulo y, a partir de ella, calcula:

$$window_mean = \frac{1}{n} \sum_{t=1}^n AQI_t, \quad (11)$$

$$exceedances = |\{AQI_t : AQI_t \geq 100\}|, \quad (12)$$

$$persistence = \min\left(100, \frac{window_mean}{3} + 15 \cdot exceedances\right). \quad (13)$$

Con ello, la persistencia no representa duración cronológica estricta, sino continuidad reciente del deterioro del AQI base en una escala operativa de 0 a 100.

En esta transición también se calcula la cobertura global de la entrada. Sin embargo, la cobertura no entra a la malla difusa principal; se conserva como indicador de completitud de datos y como criterio de cautela en la salida.

Núcleo de evaluación y motor difuso

El núcleo IA del prototipo se organiza en dos niveles de decisión. El primero es determinista y produce el estado base del aire. El segundo es difuso y ajusta ese estado en función de variables agregadas. La Figura 9 resume esta estructura.

Estructura de decision del modulo IA




Figura 9. Estructura de decisión implementada en el núcleo IA del módulo. Elaboración propia.

El motor principal se implementó con inferencia *Mamdani*. La elección respondió a interpretabilidad, auditabilidad y control directo sobre las funciones de pertenencia y la base de reglas. La malla principal quedó definida sobre tres variables:

1. **AQI base** con seis categorías EPA.
2. **Concurrencia** con tres niveles: baja, media y alta.
3. **Persistencia** con tres niveles: baja, media y alta.

Esta combinación produce una base completa de 54 reglas. La Tabla 4 resume la lógica por bloques y el detalle completo se presenta en el Anexo 4, Tabla 11. La decisión de utilizar una malla completa y no una base reducida deriva de dos criterios: exhaustividad de cobertura y defensa metodológica frente a tribunal. También es consistente con antecedentes que documentan bases explícitas de 36 y 64 reglas cuando el sistema difuso trabaja sobre entradas instrumentales directas (Sung y cols., 2024; Istiqomah y cols., 2021; Zareb y cols., 2021).

AQI base	Condición de entrada dominante	Respuesta base del bloque	Escalado máximo dentro del bloque
Good	Concurrencia y persistencia bajas	Se mantiene en <i>Good</i>	Puede escalar a <i>Unhealthy for Sensitive Groups</i> cuando concurrencia y persistencia son altas.
Moderate	Baja concurrencia y baja persistencia	Se mantiene en <i>Moderate</i>	Puede escalar a <i>Unhealthy</i> .
Unhealthy for Sensitive Groups	Episodio con deterioro inicial y sin combinación severa	Se mantiene en <i>Unhealthy for Sensitive Groups</i>	Puede escalar a <i>Very Unhealthy</i> .
Unhealthy	Episodio deteriorado con presión moderada de concurrencia o persistencia	Se mantiene en <i>Unhealthy</i>	Puede escalar a <i>Hazardous</i> .
Very Unhealthy	Episodio severo desde la base normativa	Se mantiene en <i>Very Unhealthy</i>	Escala rápidamente a <i>Hazardous</i> en combinaciones medias o altas.
Hazardous	Episodio extremo desde la base normativa	Permanece en <i>Hazardous</i>	No existe escalado adicional.

Tabla 4. Resumen por bloques de la base principal de 54 reglas del motor difuso.

La capa contextual se resolvió con una base independiente de 9 reglas sobre temperatura y humedad. Esta capa no es difusa: clasifica ambas variables mediante cortes crisp y consulta una matriz 3×3 para decidir si propone o no un escalado de una categoría. Su papel es modular la salida principal cuando el riesgo base ya se encuentra comprometido y el contexto ambiental resulta menos favorable. La Tabla 5 presenta esta base.

Temperatura	Humedad	Ajuste aplicado
Baja	Baja	No modifica la salida de la capa principal.
Baja	Media	No modifica la salida de la capa principal.
Baja	Alta	No modifica la salida de la capa principal.
Normal	Baja	No modifica la salida de la capa principal.
Normal	Media	No modifica la salida de la capa principal.

Continued on next page

(Continued)

Temperatura	Humedad	Ajuste aplicado
Normal	Alta	Escala una categoría cuando el riesgo base ya se encuentra comprometido.
Alta	Baja	No modifica la salida de la capa principal.
Alta	Media	Escala una categoría cuando el riesgo base ya se encuentra comprometido.
Alta	Alta	Escala una categoría cuando el riesgo base ya se encuentra comprometido.

Tabla 5. Base contextual de 9 reglas para temperatura y humedad.

El mecanismo de inferencia del motor principal utiliza implicación por mínimo, agregación por máximo y defuzzificación por centroide discreto en el rango 0–500. La etiqueta principal se obtiene mediante bandas equivalentes a la taxonomía EPA. Después, la capa contextual crisp decide si mantiene esa salida o la escala una categoría adicional. Este diseño permite explicar qué regla difusa se activó, qué regla contextual se evaluó y cómo se obtuvo la categoría final.

Implementación del prototipo

El prototipo se implementó en Python 3.12 bajo el paquete `aqrisk`. La estructura del software separa las responsabilidades principales:

- `domain`: modelos de datos y estructuras del recorrido.
- `ingestion`: cliente de OpenAQ y construcción de series por sensor.
- `processing`: cobertura, persistencia, concurrencia y ajuste contextual.
- `aqi`: cálculo del AQI base con ventanas regulatorias.
- `fuzzy`: funciones de pertenencia, matriz de reglas y motor Mamdani.
- `alerting`: composición de la alerta y de la cautela operativa.
- `application`: orquestación del pipeline.
- `interfaces`: interfaz de línea de comandos.

La ejecución local puede realizarse directamente en Python o mediante Docker. Sobre ese núcleo se implementó además una API HTTP y una interfaz web orientada a control, visualización, explicabilidad y revisión histórica de corridas. La interfaz permite seleccionar entradas, consultar escenarios, visualizar subíndices, reglas activadas, curvas de

pertenencia y comparación entre ejecuciones. La gestión de usuarios, roles y administración todavía no forma parte del alcance actual.

Estrategia de verificación del artefacto

La verificación actual del prototipo se centró en completitud del pipeline, coherencia de la salida, trazabilidad de reglas y estabilidad básica de ejecución. Para ello se implementaron pruebas de humo sobre el modo sintético y sobre la validación mínima del modo *OpenAQ*. También se ejecutó un escenario *mock* con cobertura total y disponibilidad completa de contaminantes criterio para comprobar la integración de las cinco capas.

5.4. Resultados

La construcción del prototipo permitió cerrar un primer artefacto funcional alineado con la metodología del TFM. El módulo ya ejecuta ingestión, normalización, control de cobertura, cálculo normativo del AQI, derivación de persistencia y concurrencia, inferencia Mamdani, ajuste contextual y composición de la alerta. Sobre este núcleo se integró una capa web de supervisión que consume la API del sistema y expone paneles de dashboard, trazabilidad, explicabilidad y evaluación.

La Tabla 6 resume la verificación funcional actual.

Componente verificado	Resultado observado
Pruebas automatizadas	Once pruebas ejecutadas correctamente sobre pipeline y API HTTP, incluyendo validación mínima del modo <i>OpenAQ</i> , persistencia en histórico y un escenario con activación múltiple de reglas.
Escenarios sintéticos <i>mock</i>	Ejecución completa del flujo en <i>urban_escalation</i> y <i>diffuse_overlap</i> , con cobertura global del 100 %, soporte para PM _{2,5} , PM ₁₀ , CO, NO ₂ , O ₃ y SO ₂ , y evidencia tanto de escalado contextual como de solape difuso.
Motor difuso principal	Activación de reglas de la malla de 54 reglas con salida trazable por nombre, fuerza de disparo y etiqueta resultante.
Capa contextual	Activación del ajuste CTX_high_high en el escenario sintético cuando temperatura y humedad se ubican en la zona alta.
Salida del prototipo	Generación de alerta interpretable y serialización del resultado en formato JSON.

Tabla 6. Verificación funcional actual del prototipo implementado.

La validación de esta etapa combinó tres fuentes de evidencia. La primera fue la suite automatizada actual, que ya cubre pipeline y API HTTP. La segunda fueron corridas

reales sobre *OpenAQ*, seleccionadas por estabilidad y valor analítico en la ventana de 24 horas consultada. La tercera fueron escenarios controlados, utilizados solo cuando era necesario mostrar comportamientos que las estaciones reales no ofrecieron de forma reproducible en esta iteración. Para la parte real se conservaron tres ubicaciones útiles: *Hospital General de México* (`location_id=1134`), *Parque O'Higgins* en Santiago (25) y *SAN BORJA* en Lima (2402). Como casos controlados se mantuvieron *urban_escalation*, para documentar un escalado contextual efectivo, y *diffuse_overlap*, para documentar una activación múltiple de reglas en el motor principal.

El *dashboard* actúa como punto de entrada de esa lectura. La Figura 10 muestra la vista principal con una corrida controlada completa. El bloque superior concentra el estado del backend, las ayudas de lectura y la exportación de evidencia. El panel de control consolida la selección de modo, escenario o estación, ventana temporal y cobertura mínima. La tarjeta de lectura ejecutiva resume AQI dominante, riesgo final, cobertura y efecto de la capa contextual. Esta síntesis permite decidir si la corrida requiere una auditoría más detallada en *Trazabilidad*, una revisión interna del razonamiento en *Explicabilidad* o una comparación con el histórico en *Evaluación*.




Figura 10. Vista principal del *dashboard* para la corrida controlada *diffuse_overlap*. La captura deja visibles el panel de control, la lectura ejecutiva del episodio y el resumen de la corrida, que sirven como punto de entrada antes de abrir las vistas analíticas. Elaboración propia.

Los colores del *dashboard* siguen una convención estable para reducir ambigüedad entre vistas. El azul identifica la base normativa y las magnitudes ligadas al AQI o a la corrida actual. El naranja se reserva para la concurrencia y, en comparaciones históricas, para la corrida de referencia. El rojo representa persistencia o presión acumulada. El verde se usa para la salida final, la cobertura útil y los estados resueltos por la capa contextual.

Esta codificación se repite en gráficas, tarjetas y comparaciones para que la semántica visual se mantenga al pasar de *Dashboard* a *Explicabilidad* o *Evaluación*.

A partir de esa vista general, el ejemplo de la Figura 11 resume tres lecturas que justifiquen la arquitectura propuesta. La subfigura 11c mantiene explícita la base normativa: O_3 domina el episodio y supera el umbral 100, mientras $PM_{2,5}$ queda en una banda inferior y el resto de contaminantes no compite por la dominancia. La subfigura 11b muestra que el artefacto obtiene un valor específico del AQI base; en el que, al implementar reglas crisp de contexto, reexpresa la escala de salida final del sistema. La subfigura 11a deja visibles las variables auxiliares con un papel separado: la persistencia añade memoria temporal, la concurrencia mide coexistencia efectiva y la cobertura se conserva como control de calidad de datos fuera de la malla difusa. Esa separación es una ventaja del diseño implementado, porque evita mezclar evidencia normativa, modulación difusa y calidad del dato en un único indicador opaco.




Figura 11. Lectura analítica del *dashboard* sobre la corrida controlada *urban_escalation*. Las subfiguras condensan la base normativa del episodio, la reexpresión de esa base en la escala de salida del sistema y el papel de las variables auxiliares que enriquecen la decisión. Elaboración propia.

A partir de la Figura 11, el resto de resultados se organiza por la pregunta que responde cada vista. *Trazabilidad* y *Explicabilidad* se apoyan en *diffuse_overlap*, porque ese escenario activa varias reglas con fuerzas distintas dentro del motor principal. *Evaluación* utiliza *urban_escalation*, ya que en ese caso la capa contextual sí altera la salida final y el escalado se vuelve observable.

La *Trazabilidad* expone el recorrido completo de la decisión y es la vista más útil para distinguir capas. El ejemplo de la Figura 12 deja leer cómo se resuelve la evaluación

mostrada. La ruta de decisión fija el orden del proceso.

Trazabilidad

Dashboard
Trazabilidad
Explicabilidad
Evaluación

Visor modal para revisar una sola sección del sistema a la vez.

Ruta de decisión

- Consolidación normativa del AQI con base en EPA/AQS.
- Cálculo de concurrencia, persistencia y cobertura del episodio.
- Aplicación de la base principal de 54 reglas.
- Ajuste contextual por temperatura y humedad cuando existen datos.
- Generación de salida final, alerta y registro histórico.

Entradas reales del motor y salidas

AQI GLOBAL
93
Dominante: o3

CONCURRENCIA
4.66
Entrada auxiliar multicontaminante

PERSISTENCIA
31.00
Continuidad temporal del AQI base

SALIDA PRINCIPAL
83.74
moderate

SALIDA FINAL
83.74
moderate

COBERTURA GLOBAL
100.0%
Calidad de dato, fuera de la malla difusa.

EXPLICACIÓN DE SALIDA FINAL
La inferencia principal produjo 83.74 (moderate). La capa contextual dejó la salida en 83.74 (moderate) porque la regla contextual CTX_normal_medium no modificó la salida principal.

Parámetros soportados
pm25 pm10 co no2 o3 so2

Parámetros sin subíndice AQI válido
ninguno

Reglas activadas

REGLA
R_moderate_low_low
Si AQI es moderate, concurrencia es low y persistencia es low, entonces la salida es moderate.
Fuerza 0.45 Salida moderate

REGLA
R_unhealthy_sensitive_groups_low_low
Si AQI es unhealthy sensitive groups, concurrencia es low y persistencia es low, entonces la salida es unhealthy sensitive groups.
Fuerza 0.09 Salida unhealthy sensitive groups

REGLA
R_moderate_low_medium
Si AQI es moderate, concurrencia es low y persistencia es medium, entonces la salida es moderate.
Fuerza 0.04 Salida moderate

REGLA
R_unhealthy_sensitive_groups_low_medium
Si AQI es unhealthy sensitive groups, concurrencia es low y persistencia es medium, entonces la salida es unhealthy sensitive groups.
Fuerza 0.04 Salida unhealthy sensitive groups

Ajustes contextuales

Temperatura disponible Humedad disponible

Regla evaluada: CTX_normal_medium

TEMPERATURA
26
Término: normal

HUMEDAD
62
Término: medium

REGLA CONTEXTUAL
CTX_normal_medium
Fuerza: 1.00 (activación crisp)
Escalado: 0 nivel(es)
Temperatura normal y humedad media: la capa contextual no escala la salida principal.

ESTADO
sin aplicación
La combinación de temperatura y humedad existe, pero la regla contextual no escala.

Sin ajuste contextual aplicado.

Cerrar

Figura 12. Modal de *Trazabilidad* para el escenario controlado *diffuse_overlap*. La captura muestra cuatro reglas de la base principal con fuerzas de disparo distintas y, en paralelo, una regla contextual crisp evaluada sin escalado, lo que permite separar con claridad inferencia difusa principal y modulación contextual posterior. Elaboración propia.

El bloque de entradas y salidas permite comprobar que el episodio parte de un AQI global 93, con concurrencia 4.66 y persistencia 31.00, y que tanto la salida principal como la salida final permanecen en *moderate*. Esta combinación ya anticipa una propiedad importante: el caso no está dominado por concurrencia alta, sino por un AQI situado en zona de transición y una persistencia con solape parcial entre *low* y *medium*. De-

bajo, las cuatro reglas activadas confirman esa lectura. Domina $R_{\text{moderate_low_low}}$, pero convive con tres reglas secundarias que introducen contribuciones moderadas y *unhealthy_sensitive_groups*. En paralelo, la regla contextual $CTX_{\text{normal_medium}}$ aparece evaluada sin escalado. La figura documenta qué módulos existen: muestra que la salida *moderate* surge de una agregación con solape real en la base difusa y que la capa crisp posterior queda visible, separada y sin efecto sobre este episodio.

La vista de *Explicabilidad* se apoya aquí en una única corrida controlada: *diffuse_overlap*. Este escenario es el más útil para inspección interna porque mantiene una salida final estable, pero activa cuatro reglas de la base principal con fuerzas distintas. La Figura 13 muestra que el peso dominante se concentra en $R_{\text{moderate_low_low}}$, mientras tres reglas de menor intensidad mantienen abierta la transición hacia categorías más severas. Esa distribución importa porque traduce la intuición del episodio a términos verificables: el sistema reconoce una base todavía moderada, pero no completamente limpia, y por eso no reduce la decisión a una sola etiqueta crisp desde el inicio.




Figura 13. Distribución de reglas activadas en la corrida controlada *diffuse_overlap*. La evaluación muestra cuatro reglas efectivamente disparadas, con una regla dominante y tres aportes secundarios, lo que confirma que el motor principal combina zonas de solape en lugar de colapsar a una única regla. Elaboración propia.




Figura 14. Lectura interna de la corrida *diffuse_overlap*. Las subfiguras muestran la evaluación que se está explicando: la agregación del motor principal y la posición del episodio dentro de las tres variables lingüísticas que alimentan la inferencia. Elaboración propia.

Las subfiguras de la Figura 14 completan esa lectura. La agregación difusa muestra cómo esos cuatro disparos se combinan en una única superficie y convergen en un score compatible con la etiqueta *moderate*. Las curvas de AQI, concurrencia y persis-

tencia explican por qué ocurre esa combinación: el AQI cae en el borde entre *moderate* y *unhealthy_sensitive_groups*, la concurrencia queda anclada en *low* y la persistencia aporta una transición entre *low* y *medium*. La ventaja de la implementación propuesta aparece justamente ahí: la salida depende del contaminante dominante y de una composición interpretable entre severidad normativa, coexistencia efectiva y continuidad temporal.




Figura 15. Modal de *Explicabilidad* para el escenario controlado *urban_escalation*. La vista resume la inferencia principal y documenta por separado la capa contextual crisp mediante bandas, términos activos, matriz de reglas 3×3 y guardarraíl particulado. Elaboración propia.

En la Figura 15 se muestra la explicabilidad de la etapa final de la capa contextual basada en reglas, pero para este ejemplo se mantiene *urban_escalation* solo para documentar

la capa contextual crisp. En esta vista ya no se discute la inferencia principal, sino el mecanismo posterior que decide si se escala o no la salida. La imagen muestra temperatura 31 y humedad 76, combinación que activa la celda *CTX_high_high*. El guardarraíl particulado permite el ajuste y la salida contextual queda marcada como *aplicado*. La utilidad analítica de esta figura demuestra que el escalado final puede justificarse con reglas discretas explícitas y valores observables, sin ocultar el punto de decisión dentro del motor principal.

El modal de *Evaluación* cierra la lectura al comparar salida principal y salida final. La Figura 16 utiliza la evaluación controlada *urban_escalation* porque en ese caso la salida final sí se separa de la salida principal y el efecto del ajuste contextual queda visible de forma directa.




Figura 16. Comparación entre salida principal y salida final en la evaluación controlada *urban_escalation*. La figura muestra explícitamente la evaluación presentada en este bloque: la capa contextual eleva la salida final respecto de la salida principal y hace visible el efecto del escalado sobre un episodio diseñado para activar esa condición. Elaboración propia.

La evidencia reunida permitió verificar cinco hechos alineados con los objetivos del TFM. El primero es que el módulo implementado ya integra base normativa, inferencia difusa, capa contextual y alertamiento en un flujo trazable de extremo a extremo. El segundo es que las corridas reales sobre distintas estaciones producen episodios diferenciados y, por tanto, ya habilitan comparación entre múltiples ciudades, aunque esa comparación todavía no constituya una evaluación extensa de desempeño. El tercero es que el escenario controlado sigue siendo necesario para documentar una alerta más severa y un escalado contextual efectivo, porque esa combinación no apareció de forma reproducible en las estaciones consultadas. El cuarto es que *diffuse_overlap* demuestra un comportamiento genuinamente difuso, con varias reglas activadas y fuerzas distintas dentro de la malla principal. El quinto es que la implementación propuesta depende del contaminante dominante e incorpora concurrencia y persistencia como entradas auxiliares interpretables, lo que refuerza la evaluación del riesgo y mejora la capacidad explicativa del artefacto.

5.5. Discusión

Los resultados presentados permiten discutir el alcance real del artefacto implementado y situarlo frente a los antecedentes comparables revisados en el SLR. La lectura comparativa se organiza alrededor de variables, arquitectura, implementación y validación, a la luz de los criterios de diseño fijados para este estudio. Desde esa base, la discusión siguiente examina qué aspectos de la propuesta responden de manera consistente a la evidencia previa, qué decisiones la distinguen dentro del campo y qué limitaciones siguen abiertas para etapas posteriores.

La caracterización del campo y la traducción de esa evidencia a decisiones concretas de diseño quedan reflejadas en la selección de variables y fuentes del prototipo. El núcleo regulatorio utiliza los seis contaminantes criterio del AQI y reserva temperatura y humedad para una capa contextual separada. Esa elección se alinea con trabajos urbanos que emplean conjuntos amplios de contaminantes y covariables ambientales, como el marco de predicción AQI presentado por Haidar y cols., basado en NO₂, O₃, PM₁₀, PM_{2,5}, CO, SO₂, temperatura, humedad, presión y UV sobre datos públicos (Haidar y cols., 2025, pp. 3–4). También mantiene un punto de contacto con las propuestas de Saini y cols. y de Zareb y cols. en el uso de temperatura y humedad como variables relevantes del entorno (Saini y cols., 2022b, pp. 3–5), (Zareb y cols., 2021, pp. 2–3, 5). La diferencia aparece en el propósito: los trabajos de Saini y cols. y de Zareb y cols. operan en calidad del aire interior y privilegian pronóstico de PM_{2,5} o estimación AQI/IAQ en espacios domésticos (Saini y cols., 2022b, pp. 1, 3–5), (Zareb y cols., 2021, pp. 1, 3–5); Kowalski y cols. se concentran en ajuste de PM_{2,5} frente a estación de referencia y no en alertamiento urbano (Kowalski y cols., 2026, pp. 5–6). En ese contexto, la propuesta articula datos abiertos urbanos y semántica normativa EPA/AQS en un módulo orientado a riesgo actual. El coste de esa decisión es que prescinde de variables frecuentes en sistemas indoor, como CO₂ o TVOC, y por ello cubre menos condiciones de confort o ventilación que algunos antecedentes (Saini y cols., 2022b, pp. 3–5), (Istiqomah y cols., 2021, p. 1).

El diseño arquitectónico también queda respaldado por la comparación con los antecedentes. La implementación comparte con los trabajos de Sung y cols., Istiqomah y cols. y Zareb y cols. la idea de tratar el monitoreo como un flujo operativo y no como una fórmula aislada: esos trabajos integran adquisición, inferencia y visualización en arquitecturas IoT con sensores, conectividad y alarmamiento (Sung y cols., 2024, pp. 7, 11–15, 24), (Istiqomah y cols., 2021, pp. 1–2, 5–6), (Zareb y cols., 2021, pp. 2–3, 5). El contraste aparece en la estructura de decisión. Sung y cols. combinan Mamdani y aprendizaje por refuerzo profundo para control industrial de aire acondicionado y buzzer en fábrica (Sung y cols., 2024, pp. 1, 7–10, 16–23); Istiqomah y cols. utilizan Tsukamoto sobre CO, CO₂ y CH₄ con alerta local transmitida por LoRa (Istiqomah y cols., 2021, pp. 2–6); Zareb y cols. emplean un FIS tipo 1 para calibración de sensores y estimación AQI indoor

(Zareb y cols., 2021, pp. 1, 3–5). La propuesta adopta otra solución: separa consolidación normativa AQI, variables auxiliares, inferencia Mamdani principal, capa contextual crisp y alertamiento. Esta partición mejora auditabilidad y permite mostrar por separado regla difusa, regla contextual y efecto final de cada capa. De ahí surge una trazabilidad del razonamiento más fuerte. El precio a pagar es la dependencia de la calidad y cobertura de fuentes abiertas, mientras los antecedentes instrumentados controlan directamente sensores, frecuencia de muestreo y contexto de despliegue (Haidar y cols., 2025, pp. 3–4), (Zareb y cols., 2021, pp. 1–2, 5).

La implementación del módulo también puede leerse a la luz de antecedentes que ya ofrecían plataforma operativa. Saini y cols. publican resultados en el portal *Vayurveda* y articulan red IoT, portal web y pronóstico casi en tiempo real (Saini y cols., 2022b, pp. 3–4, 9–11). Sung y cols. reportan integración con Firebase, aplicación móvil y sitio web para supervisión y control (Sung y cols., 2024, pp. 1, 11–15). Zareb y cols. usan Google Sheets y una aplicación web ligera para seguimiento del dispositivo indoor (Zareb y cols., 2021, pp. 2–3, 5). La implementación se acerca a esas propuestas en la entrega de un artefacto ejecutable con interfaz de usuario. La diferencia relevante está en el tipo de interfaz implementada: el frontend actual expone *dashboard*, trazabilidad, explicabilidad y evaluación sobre la misma corrida. Ese rasgo se aprecia con mayor claridad frente a los trabajos de Haidar y cols. y Kowalski y cols. Haidar y cols. reportan un marco híbrido ANFIS+ML+BMN para predicción AQI urbana, pero no documentan una interfaz operativa equivalente ni un despliegue reproducible con API, historiales y auditoría de reglas (Haidar y cols., 2025, pp. 1, 4–5). Kowalski y cols. priorizan reducción explicable de reglas dentro de ANFIS para ajuste de $PM_{2,5}$, con una contribución fuerte en interpretabilidad del modelo, aunque sin presentar una plataforma de monitoreo y alertamiento de extremo a extremo (Kowalski y cols., 2026, pp. 1–5, 8–10). En consecuencia, la propuesta integra explicabilidad del modelo dentro de un artefacto operativo. A la vez, su persistencia histórica aún es básica y no ofrece actuación física ni administración completa de plataforma, capacidades que sí aparecen en sistemas IoT instrumentados como el de Sung y cols. (Sung y cols., 2024, pp. 11–15).

La validación es el punto donde la comparación exige mayor precisión metodológica. Los antecedentes reportan validaciones cuantitativas fuertes, pero sobre salidas distintas a las de esta propuesta. Haidar y cols. informan R^2 y MSE en diez particiones aleatorizadas para predicción AQI (Haidar y cols., 2025, pp. 4–5). Kowalski y cols. evalúan MAE, RMSE y correlación de Pearson en múltiples localizaciones para ajuste de $PM_{2,5}$ (Kowalski y cols., 2026, pp. 6, 9–12). Sung y cols. añaden exactitud, pérdida, memoria e inferencia en milisegundos para un sistema de control industrial (Sung y cols., 2024, pp. 16–25). Istiqomah y cols. reportan exactitud de 92.4 % con la segunda base de reglas Tsukamoto (Istiqomah y cols., 2021, pp. 4–6). La implementación presentada no persigue una salida predictiva ni una calibración de sensor; su validación se centra en coherencia de la salida, activación de reglas, utilidad operativa de la interfaz y contraste entre corridas

reales y escenarios controlados. Esta elección mantiene correspondencia con un módulo orientado a evaluación actual del riesgo y alertamiento. El beneficio inmediato es la coherencia entre objetivo, arquitectura y evidencia presentada. La deuda pendiente es una evaluación comparativa extensa entre múltiples estaciones, particiones temporales y métricas agregadas del tipo usado por Haidar y cols. o Kowalski y cols. (Haidar y cols., 2025, pp. 4–5), (Kowalski y cols., 2026, pp. 9–12). En conjunto, la discusión muestra que la propuesta avanza sobre una zona menos explotada del campo: módulos urbanos explicables apoyados en datos abiertos y diseñados para auditoría operativa, aunque todavía con margen claro de fortalecimiento en validación externa y persistencia de largo plazo.

La integración con *OpenAQ* quedó validada a nivel de código, configuración y cliente de consulta. El prototipo recupera estaciones por *location_id*, consulta sensores asociados y construye series horarias por parámetro. Las corridas reales también hicieron visible una limitación importante: no toda estación con sensores publicados produce una ventana útil para el modelo. Un ejemplo es *Adrogué* en Buenos Aires (2847298), cuya ficha expone $PM_{2,5}$, PM_{10} , temperatura y humedad relativa en *OpenAQ*, pero cuya ventana consultada devolvió series vacías, cobertura global nula y una categoría *sin_datos*. Esa restricción forma parte del comportamiento real del sistema sobre datos abiertos vivos y debe conservarse explícitamente en la evaluación.

En el estado actual del trabajo, el resultado principal no es todavía una comparación extensa de desempeño entre múltiples estaciones. El resultado alcanzado es la construcción de un artefacto ejecutable, trazable y explicable, con base normativa explícita, base principal de 54 reglas, capa contextual de 9 reglas, API HTTP, despliegue en contenedores e interfaz web inicial lista para etapas posteriores de validación comparativa y consolidación operativa.

6. Conclusiones y Trabajos Futuros

El desarrollo presentado permitió alcanzar, en un estado funcional inicial, la construcción de un módulo de monitoreo de calidad del aire apoyado en inferencia difusa y datos abiertos. La revisión sistemática del estado del arte permitió caracterizar variables, enfoques difusos y arquitecturas operativas recientes, y aportó la base empírica necesaria para justificar el problema de investigación y derivar criterios explícitos de diseño. Con ello, la propuesta quedó sustentada sobre criterios trazables y coherentes con la evidencia reciente, no sobre decisiones arbitrarias o desvinculadas del campo.

A partir de esa base, se definió e implementó el prototipo *AQRisk*, organizado en cinco capas funcionales: consolidación normativa, variables auxiliares, inferencia difusa principal, capa contextual basada en reglas y alertamiento. La arquitectura implementada integra cálculo del AQI con base en *EPA/AQS*, una base principal de 54 reglas difusas, una base contextual crisp de 9 reglas, control de cobertura de datos, ejecución por CLI y Docker, API HTTP e interfaz web para control, visualización, trazabilidad, explicabilidad y evaluación. Este resultado muestra que la arquitectura funcional propuesta pudo traducirse en un artefacto ejecutable y auditable, con una separación explícita entre la capa normativa, la inferencia difusa principal y el ajuste contextual posterior.

La validación realizada en esta etapa confirma la operabilidad del flujo completo del sistema y la coherencia general de la salida frente a escenarios controlados y consultas reales sobre datos abiertos. La evidencia reunida ya no se limita a pruebas de humo: incluye pruebas automatizadas básicas, corridas reales sobre estaciones con comportamiento útil, evidencia visual por modal y comparación con corridas históricas. El prototipo permite inspeccionar contaminantes soportados, reglas activadas, variables auxiliares, ajuste contextual y diferencias entre episodios reales y controlados. En consecuencia, existe verificación funcional suficiente para sostener la utilidad técnica del artefacto como módulo de apoyo a la evaluación del riesgo y a la generación de alertas, aunque todavía no una evaluación comparativa extensa entre múltiples estaciones, ventanas temporales y condiciones urbanas diversas.

Entre las principales limitaciones del trabajo actual se encuentran la dependencia de disponibilidad y cobertura efectiva en fuentes abiertas vivas, la validación todavía acotada en escenarios reales y la ausencia de una capa completa de gestión de usuarios, roles y administración. Las corridas con datos abiertos también mostraron que no toda estación con sensores publicados ofrece una ventana útil para el modelo, lo que condiciona la comparabilidad entre ciudades y obliga a mantener criterios explícitos de selección de casos. Estas restricciones no invalidan el artefacto, pero sí delimitan el alcance de los

resultados presentados: la contribución central del TFM es la construcción y justificación de un módulo explicable, trazable y reproducible para evaluación actual del riesgo, no una plataforma productiva plenamente desplegada a escala urbana. Entre las principales limitaciones del trabajo actual se encuentran la dependencia de disponibilidad y cobertura efectiva en fuentes abiertas vivas, la validación todavía acotada en escenarios reales y la ausencia de una capa completa de gestión de usuarios, roles y administración. Las corridas con datos abiertos también mostraron que no toda estación con sensores publicados ofrece una ventana útil para el modelo, lo que condiciona la comparabilidad entre ciudades y obliga a mantener criterios explícitos de selección de casos. Estas restricciones no invalidan el artefacto, pero sí delimitan el alcance de los resultados presentados: la contribución central de la propuesta es la construcción y justificación de un módulo explicable, trazable y reproducible para evaluación actual del riesgo, no una plataforma productiva plenamente desplegada a escala urbana.

Como trabajo futuro inmediato, resulta pertinente ampliar la validación comparativa del módulo con más estaciones, más horizontes temporales y casos de alerta de mayor diversidad, además de endurecer la cobertura de pruebas API y E2E. También resulta razonable reforzar la persistencia de corridas con una base de datos más robusta que el histórico local actual, de forma que la comparación temporal deje de depender de almacenamiento básico en el prototipo. En una fase posterior, la implementación podría evolucionar hacia funciones de autenticación, administración y exposición pública controlada, así como hacia una comparación experimental entre la capa contextual crisp actual y una eventual variante contextual difusa.

7. Referencias

- Andrianto, R., Purnomo, N., y Irawan, Y. (2024). Application of fuzzy logic mamdani in iot-based air quality monitoring systems. *The Indonesian Journal of Computer Science*, 13(5). doi: 10.33022/ijcs.v13i5.4291
- Behal, V., y Singh, R. K. (2021). Personalised healthcare model for monitoring and prediction of airpollution: machine learning approach [Article]. *Journal of Experimental and Theoretical Artificial Intelligence*, 33(3), 425 - 449. Descargado de <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85083649233&doi=10.1080%2F0952813X.2020.1744197&partnerID=40&md5=c1e585b13d86b203b47678ff64b18cb9> (Cited by: 14) doi: 10.1080/0952813X.2020.1744197
- Bushnag, A. (2023). An improved air quality and climate control monitoring system using fuzzy logic for enclosed areas [Article]. *Journal of Ambient Intelligence and Humanized Computing*, 14(5), 6339 - 6347. Descargado de <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85127252487&doi=10.1007%2Fs12652-022-03814-z&partnerID=40&md5=2e591f76d9c0f2ef7e545211f8829678> (Cited by: 13) doi: 10.1007/s12652-022-03814-z
- Chen, S. (2017). *Beijing multi-site air quality [dataset]*. UCI Machine Learning Repository. Descargado de <https://archive.ics.uci.edu/dataset/501/beijing+multi+site+air+quality+data> (Consultado el 24 de febrero de 2026) doi: 10.24432/C5RK5G
- de Assis Pedrobon Ferreira, W., Grout, I. A., y da Silva, A. C. R. (2022). Application of a fuzzy artmap neural network for indoor air quality prediction [Conference paper]. Institute of Electrical and Electronics Engineers Inc. Descargado de <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85128177831&doi=10.1109%2FiEECON53204.2022.9741563&partnerID=40&md5=7bb1f207e87db8111d8c8ce59b13a06d> (Cited by: 8) doi: 10.1109/IEECON53204.2022.9741563
- Erfianto, B., y Rahmatsyah, A. (2022). Application of arima kalman filter with multi-sensor data fusion fuzzy logic to improve indoor air quality index estimation [Article]. *International Journal on Informatics Visualization*, 6(4), 771 - 777. Descargado de <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85145950935&doi=10.30630%2Fjoiv.6.4.889&partnerID=40&md5=730057150342c14ff56523bb7c26fe19> (Cited by: 7; All Open Access; Gold Open Access) doi: 10.30630/joiv.6.4.889
- Geron, A. (2023). *Hands-on machine learning with scikit-learn, keras, and tensorflow* (3.^a ed.). O'Reilly Media.
- Haidar, I. M., Itani, S. S., Kaouk, A., Kaddah, A., Alloul, D. A., y Doughan, Z. (2025). Urban

- air quality analysis using ensemble learning [Conference paper]. Institute of Electrical and Electronics Engineers Inc. Descargado de <https://www.scopus.com/inward/record.uri?eid=2-s2.0-10502448488&doi=10.1109%2FICABME66883.2025.11211707&partnerID=40&md5=ef4761cda0e485abcd55536b350c7db5> (Cited by: 0) doi: 10.1109/ICABME66883.2025.11211707
- Hevner, A. R., March, S. T., Park, J., y Ram, S. (2004). Design science in information systems research. *MIS Quarterly*, 28(1), 75–105. Descargado de <https://www.jstor.org/stable/25148625>
- Istiqomah, N., Yuliana, M., y Santoso, T. B. (2021). Implementation of fuzzy tsukamoto algorithm on smart node sensors for air quality monitoring [Conference paper]. En A. Yunanto y cols. (Eds.), (p. 275 - 280). Institute of Electrical and Electronics Engineers Inc. Descargado de <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85119959349&doi=10.1109%2FIES53407.2021.9594014&partnerID=40&md5=1bf47d616c161ed90b99f8c7b2ca9f2d> (Cited by: 1) doi: 10.1109/IES53407.2021.9594014
- K, P., y Kumar, P. (2022). A critical evaluation of air quality index models (1960–2021). *Environmental Monitoring and Assessment*, 194, 324. doi: 10.1007/s10661-022-09896-8
- Kitchenham, B., y Charters, S. (2007). *Guidelines for performing systematic literature reviews in software engineering* (Inf. Téc. n.º EBSE-2007-01). Keele University and Durham University. (Version 2.3)
- Kowalski, P. A., Casari, M., y Po, L. (2026). Explainable ai for rule reduction in fuzzy models for air pollution measurement adjustment [Article]. *Environmental Modelling and Software*, 195. Descargado de <https://www.scopus.com/inward/record.uri?eid=2-s2.0-105018450961&doi=10.1016%2Fj.envsoft.2025.106734&partnerID=40&md5=4491aab1e394b4dbc92e42f19152b68e> (Cited by: 1; All Open Access; Green Accepted Open Access; Green Open Access; Hybrid Gold Open Access) doi: 10.1016/j.envsoft.2025.106734
- Lingaraj, K., Malghan, R. L., Rao, K., Garg, L., Somanath Swamy, R. H., y Vishwanatha, H. M. (2025). Flpso-amps: an optimized wsn model for air quality monitoring in tier-2 smart cities [Article]. *Scientific Reports*, 15(1). Descargado de <https://www.scopus.com/inward/record.uri?eid=2-s2.0-105018817483&doi=10.1038%2Fs41598-025-19748-3&partnerID=40&md5=d1d75419309eab5d7de81771ad8dd670> (Cited by: 0; All Open Access; Gold Open Access; Green Accepted Open Access; Green Open Access) doi: 10.1038/s41598-025-19748-3
- Olivas, J. A. (2003). *La logica borrosa y sus aplicaciones*. (Documento tecnico, PDF)
- Olivas, J. A. (2019). *Logica borrosa y razonamiento aproximado*. (Material docente, PDF)
- OpenAQ. (2026). *Openaq platform and api documentation*. OpenAQ. Descargado de <https://openaq.org/> (Consultado el 24 de febrero de 2026)
- Page, M. J., McKenzie, J. E., Bossuyt, P. M., Boutron, I., Hoffmann, T. C., Mulrow, C. D.,

- ... Moher, D. (2021). The prisma 2020 statement: an updated guideline for reporting systematic reviews. *BMJ*, 372, n71. doi: 10.1136/bmj.n71
- Peffer, K., Tuunanen, T., Rothenberger, M. A., y Chatterjee, S. (2008). A design science research methodology for information systems research. *Journal of Management Information Systems*, 24(3), 45–77. doi: 10.2753/MIS0742-1222240302
- Saini, J., Dutta, M., y Marques, G. (2022a). Adfist: Adaptive dynamic fuzzy inference system tree driven by optimized knowledge base for indoor air quality assessment [Article]. *Sensors*, 22(3). Descargado de <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85123527715&doi=10.3390%2Fs22031008&partnerID=40&md5=ffb30b7ceea905fb8f721695f70c3f7a> (Cited by: 22; All Open Access; Gold Open Access; Green Accepted Open Access; Green Open Access) doi: 10.3390/s22031008
- Saini, J., Dutta, M., y Marques, G. (2022b). Modeling indoor pm2.5 using adaptive dynamic fuzzy inference system tree (adfist) on internet of things-based sensor network data [Article]. *Internet of Things (Netherlands)*, 20. Descargado de <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85140483465&doi=10.1016%2Fj.iot.2022.100628&partnerID=40&md5=072e3dc27c34d1a952ddeb97db254a91> (Cited by: 12) doi: 10.1016/j.iot.2022.100628
- Saleem, M., Shingari, N., Farooq, M. S., Mago, B., y Khan, M. A. (2024). Real-time air quality monitoring model using fuzzy inference system [Article]. *International Journal of Advanced Computer Science and Applications*, 15(6), 838 - 846. Descargado de <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85198293522&doi=10.14569%2FIJACSA.2024.0150684&partnerID=40&md5=f78d46ce9c42d591d7624491e738933e> (Cited by: 2; All Open Access; Gold Open Access) doi: 10.14569/IJACSA.2024.0150684
- Seibert, V. A., Bastos, R., Maia, G., Lucca, G., Santos, H., Yamin, A., y Reiser, R. H. R. (2024). Toward air quality fuzzy classification.. doi: 10.5220/0012689000003690
- Suman. (2020). Air quality indices: A review of methods to interpret air quality status. *Materials Today: Proceedings*. doi: 10.1016/j.matpr.2020.07.141
- Sung, W. T., Aryani, J., y Sung-Jung, H. (2024). Intelligent factory with environment quality control based on fuzzy method through deep reinforcement learning [Article]. *Sensors and Materials*, 36(8), 3491 - 3517. Descargado de <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85202751409&doi=10.18494%2FSAM4661&partnerID=40&md5=8b0c1e9ecc69b706b8604360e4faa639> (Cited by: 0; All Open Access; Gold Open Access) doi: 10.18494/SAM4661
- Sutton, R. S., y Barto, A. G. (2018). *Reinforcement learning: An introduction* (2.^a ed.). MIT Press.
- United States Environmental Protection Agency. (2024). *Technical assistance document for the reporting of daily air quality – the air quality index (aqi)*. AirNow. Descargado de <https://document.airnow.gov/technical-assistance-document-for-the-reporting-of-daily-air-quailty.pdf> (Consultado el 13 de abril de 2026)

- United States Environmental Protection Agency. (2026). *Aqi breakpoints*. EPA Air Quality System (AQS). Descargado de https://aqs.epa.gov/aqsweb/documents/codetables/aqi_breakpoints.html (Consultado el 29 de marzo de 2026)
- Vito, S. D. (2008). *Air quality [dataset]*. UCI Machine Learning Repository. Descargado de <https://archive.ics.uci.edu/dataset/360/air+quality> (Consultado el 24 de febrero de 2026) doi: 10.24432/C59K5F
- Zadeh, L. A. (1973). Outline of a new approach to the analysis of complex systems and decision processes. *IEEE Transactions on Systems, Man, and Cybernetics*, SMC-3(1), 28–44.
- Zareb, M., Bakhti, B., Bouzid, Y., Batista, C. E., Ternifi, I., y Abdenour, M. (2021). An intelligent iot fuzzy based approach for automated indoor air quality monitoring [Conference paper]. En (p. 770 - 775). Institute of Electrical and Electronics Engineers Inc. Descargado de <https://www.scopus.com/inward/record.uri?eid=2-s2.0-85113621354&doi=10.1109%2FMED51440.2021.9480313&partnerID=40&md5=aeea33520cfccef2e1cec7607a836d64> (Cited by: 10) doi: 10.1109/MED51440.2021.9480313

Lista de Acrónimos

- AQI** Air Quality Index.
- ANFIS** Adaptive Neuro-Fuzzy Inference System.
- AQS** Air Quality System.
- API** Application Programming Interface.
- CLI** Command-Line Interface.
- CO** Carbon Monoxide.
- CO₂** Carbon Dioxide.
- CSV** Comma-Separated Values.
- DRL** Deep Reinforcement Learning.
- DSR** Design Science Research.
- DSRM** Design Science Research Methodology.
- E2E** End-to-End.
- EPA** Environmental Protection Agency.
- FIS** Fuzzy Inference System.
- HTTP** Hypertext Transfer Protocol.
- IAQ** Indoor Air Quality.
- IoT** Internet of Things.
- JSON** JavaScript Object Notation.
- LoRa** Long Range.
- MAE** Mean Absolute Error.
- MSE** Mean Squared Error.
- MQ** Semiconductor gas sensor family MQ.
- NO₂** Nitrogen Dioxide.
- O₃** Ozone.



OpenAQ Open Air Quality platform.

PM₁₀ Particulate Matter below 10 micrometers.

PM_{2,5} Particulate Matter below 2.5 micrometers.

RMSE Root Mean Square Error.

R² Coefficient of Determination.

SLR Systematic Literature Review.

SO₂ Sulfur Dioxide.

TVOC Total Volatile Organic Compounds.

UV Ultraviolet.

VOC Volatile Organic Compounds.

WSN Wireless Sensor Network.

Anexo I

Checklist de Evaluación de Calidad

Código	Pregunta operativa	Etapas	Aplicabilidad por subtipo
QA_I01	¿Los objetivos del estudio están claramente definidos?	Diseño	General (Exp, Corr, Q-NS)
QA_I02	¿Las medidas definidas permiten responder la pregunta del estudio?	Diseño	Solo Exp
QA_I03	¿Se justifica el tamaño de muestra o número de observaciones?	Diseño	Solo Exp
QA_I04	¿La tecnología/sistema evaluado está claramente descrito?	Diseño	General (Exp, Corr, Q-NS)
QA_I05	¿Las variables clave se miden adecuadamente?	Ejecución	General (Exp, Corr, Q-NS)
QA_I06	¿Las medidas e indicadores están definidos de forma completa?	Ejecución	General (Exp, Corr, Q-NS)
QA_I07	¿Las medidas seleccionadas son relevantes para la pregunta del estudio?	Diseño	General (Exp, Corr, Q-NS)
QA_I08	¿El alcance del estudio es suficiente para sostener sus conclusiones?	Diseño	Exp y Q-NS
QA_I09	¿Los métodos de recolección de datos están descritos?	Ejecución	General (Exp, Corr, Q-NS)
QA_I10	¿Se explican los tipos y fuentes de datos utilizados?	Ejecución	General (Exp, Corr, Q-NS)
QA_I11	¿Las unidades de medida están claramente especificadas?	Ejecución	General (Exp, Corr, Q-NS)
QA_I12	¿Se reportan los datos básicos necesarios para interpretar resultados?	Ejecución	General (Exp, Corr, Q-NS)
QA_I13	¿Se describen los métodos estadísticos o analíticos empleados?	Análisis	General (Exp, Corr, Q-NS)
QA_I14	¿Se referencia el software/herramienta usada para el análisis?	Análisis	General (Exp, Corr, Q-NS)

Continued on next page

(Continued)

Código	Pregunta operativa	Etapas	Aplicabilidad por subtipo
QA_I15	¿Se justifica la elección de los métodos de análisis?	Análisis	General (Exp, Corr, Q-NS)
QA_I16	¿El propósito del análisis está claramente establecido?	Análisis	General (Exp, Corr, Q-NS)
QA_I17	¿Se describe el sistema de puntuación o criterios de evaluación del experimento?	Análisis	Solo Exp
QA_I18	¿Se controlan o discuten variables de confusión relevantes?	Análisis	General (Exp, Corr, Q-NS)
QA_I19	¿Existe consistencia numérica entre tablas, texto y resultados?	Análisis	General (Exp, Corr, Q-NS)
QA_I20	¿Se aborda el riesgo de sesgo de selección?	Análisis	Exp y Q-NS
QA_I21	¿El estudio responde explícitamente sus preguntas/objetivos?	Resultados y discusión	General (Exp, Corr, Q-NS)
QA_I22	¿Los hallazgos principales se interpretan con claridad?	Resultados y discusión	General (Exp, Corr, Q-NS)
QA_I23	¿Se reportan también hallazgos negativos o no favorables?	Resultados y discusión	General (Exp, Corr, Q-NS)
QA_I24	¿Se discute la significancia práctica de los resultados?	Resultados y discusión	General (Exp, Corr, Q-NS)
QA_I25	¿Se interpretan resultados nulos o no concluyentes?	Resultados y discusión	General (Exp, Corr, Q-NS)
QA_I26	¿Se discute si pudieron omitirse efectos relevantes?	Resultados y discusión	General (Exp, Corr, Q-NS)
QA_I27	¿Los resultados se comparan con estudios previos?	Resultados y discusión	General (Exp, Corr, Q-NS)
QA_I28	¿Se explica el aporte del estudio al estado del arte?	Resultados y discusión	General (Exp, Corr, Q-NS)
QA_I29	¿Se presentan implicaciones para práctica/sistemas reales?	Resultados y discusión	General (Exp, Corr, Q-NS)
QA_I30	¿Se explican consecuencias para validez/confiabilidad y trabajo futuro?	Resultados y discusión	General (Exp, Corr, Q-NS)

Tabla 7. Checklist de evaluación de calidad adaptado de Kitchenham (2007), con aplicación condicionada por subtipo cuantitativo. Elaboración propia.

Anexo II

Diccionario Operativo de la Matriz de Extracción

Bloque	Campo	Descripción operacional
Meta	Article_ID	Identificador único del estudio en la revisión.
Meta	Title	Título del artículo.
Meta	Year	Año de publicación.
Meta	Venue	Revista o congreso de publicación.
Meta	DOI_or_URL	DOI o enlace trazable de la fuente.
Meta	Study_type_quant	Subtipo cuantitativo aplicado en evaluación metodológica.
Meta	Country_or_region	País o región del caso de estudio cuando es reportado.
D1	D1_Pollutants_inputs	Contaminantes atmosféricos usados como entradas.
D1	D1_Env_variables_inputs	Variables ambientales no contaminantes usadas como entradas.
D1	D1_Target_output	Variable objetivo reportada por el estudio.
D1	D1_Reported_input_values	Rangos o valores numéricos de variables de entrada reportados por el estudio.
D1	D1_Sampling_frequency_values	Frecuencia de muestreo o periodicidad de adquisición.
D1	D1_Time_window_values	Ventana temporal, periodo de captura o duración del dataset.
D1	D1_Data_source_type	Tipo de fuente de datos (sensores, datasets públicos, híbrido, etc.).
D1	D1_Preprocessing	Pasos de preprocesamiento aplicados antes del modelado.
D2	D2_Fuzzy_approach_type	Tipo de enfoque difuso implementado (Mamdani, Sugeno, ANFIS, etc.).
D2	D2_Fuzzy_role	Rol del componente difuso en la solución (central, comparativo, complementario).
D2	D2_Model_size_values	Tamaño/estructura del modelo (entradas, reglas, capas, estados).
D2	D2_Optimization_values	Parámetros o métodos de optimización/entrenamiento reportados.

Continued on next page

(Continued)

Bloque	Campo	Descripción operacional
D2	D2_Inference_purpose	Propósito funcional de la inferencia difusa (estimación, clasificación, alerta, ruta).
D2	D2_Rule_base_definition	Forma de definición de la base de reglas.
D2	D2_Membership_functions	Tipo de funciones de pertenencia y representación lingüística.
D2	D2_Defuzzification_method	Método de defuzzificación reportado.
D2	D2_Risk_modeling_approach	Enfoque para traducir inferencia a riesgo o severidad.
D2	D2_Interpretability_elements	Elementos explícitos de interpretabilidad (reglas, tablas, gráficos, etc.).
D3	D3_Platform_architecture	Arquitectura de plataforma/sistema de monitoreo.
D3	D3_Processing_mode	Modo de procesamiento (tiempo real, casi real, híbrido, offline).
D3	D3_Communication_and_tech	Tecnologías de comunicación, software y servicios usados.
D3	D3_Visualization_alerting	Mecanismos de visualización y alertamiento implementados.
D3	D3_Deployment_context	Contexto de despliegue (indoor/outdoor, urbano, industrial, etc.).
D3	D3_Hardware_and_sensors	Hardware y sensores utilizados en implementación/medición.
D3	D3_Real_time_characteristics	Características operativas de comportamiento en tiempo real.
Eval	Eval_Metrics_reported	Métricas de desempeño reportadas por el estudio.
Eval	Eval_Reported_values	Valores numéricos de las métricas reportadas.
Eval	Eval_Comparator_values	Resultados de comparación con baseline/modelos alternativos.
Eval	Eval_Improvement_reported	Mejoras cuantificadas o declaradas frente a referencias.
Eval	Eval_Dataset_size_values	Tamaño del dataset, muestras o registros usados en evaluación.
Eval	Eval_Data_split_values	Esquema de partición de datos para entrenamiento/validación/prueba.
Eval	Eval_Key_results_summary	Síntesis técnica breve de resultados principales del estudio.

Continued on next page

(Continued)

Bloque	Campo	Descripción operacional
Synth	Main_contribution_reported	Contribución principal declarada para síntesis narrativa.
Synth	Main_limitation_reported	Limitación principal reportada para discusión crítica.
Synth	Evidence_D1_pages	Páginas de soporte para campos D1.
Synth	Evidence_D2_pages	Páginas de soporte para campos D2.
Synth	Evidence_D3_pages	Páginas de soporte para campos D3.
Synth	Evidence_Eval_pages	Páginas de soporte para resultados de evaluación.
Synth	QA_Quality_band	Banda de calidad metodológica del estudio (Alta/Media/Baja).
Synth	QA_Score_percent	Puntaje porcentual de calidad metodológica.
Synth	Sensitivity_set	Etiqueta de inclusión para análisis de sensibilidad de síntesis.

Tabla 8. Diccionario operativo de campos de la matriz final de extracción de datos.

Anexo III

Tabla Principal de Evidencia Cuantitativa D3

Dimensión	Categoría	k	n	%
Arquitectura de plataforma	IoT borde-nube	6	19	31.6
Arquitectura de plataforma	IoT de dos capas	5	19	26.3
Arquitectura de plataforma	Nodo sensor con analítica externa	2	19	10.5
Arquitectura de plataforma	Canal WSN	2	19	10.5
Arquitectura de plataforma	IoT-Fog por capas	1	19	5.3
Arquitectura de plataforma	Nodo independiente con PC	1	19	5.3
Modo de procesamiento	Casi tiempo real	7	19	36.8
Modo de procesamiento	Tiempo real en borde	5	19	26.3
Modo de procesamiento	Híbrido	4	19	21.1
Modo de procesamiento	Analítica fuera de línea	1	19	5.3
Modo de procesamiento	Tiempo real distribuido	1	19	5.3
Comunicación/tecnología	MATLAB	7	19	36.8
Comunicación/tecnología	Servidor en nube	6	19	31.6
Comunicación/tecnología	WiFi	6	19	31.6
Comunicación/tecnología	MCU Arduino	4	19	21.1
Comunicación/tecnología	ESP8266	3	19	15.8
Comunicación/tecnología	ESP32	3	19	15.8
Comunicación/tecnología	ThingSpeak	3	19	15.8
Comunicación/tecnología	Bluetooth	3	19	15.8
Comunicación/tecnología	Python	2	19	10.5

Continued on next page

(Continued)

Dimensión	Categoría	k	n	%
Comunicación/tecnología	Raspberry Pi	2	19	10.5
Comunicación/tecnología	Zigbee	2	19	10.5
Comunicación/tecnología	AWS EC2	1	19	5.3
Comunicación/tecnología	I2C	1	19	5.3
Comunicación/tecnología	LoRa	1	19	5.3
Comunicación/tecnología	Google Sheets	1	19	5.3
Comunicación/tecnología	HDFS MapReduce	1	19	5.3
Comunicación/tecnología	Google Map	1	19	5.3
Comunicación/tecnología	Otro: ATmega32	1	19	5.3
Comunicación/tecnología	Otro: Android Studio	1	19	5.3
Comunicación/tecnología	Otro: AWS IoT	1	19	5.3
Comunicación/tecnología	Otro: Ethernet	1	19	5.3
Comunicación/tecnología	Otro: Firebase	1	19	5.3
Comunicación/tecnología	Otro: Gateway LAN	1	19	5.3
Comunicación/tecnología	Otro: Arduino Controllers	1	19	5.3
Comunicación/tecnología	Otro: BluEpyc	1	19	5.3
Comunicación/tecnología	Otro: CAN	1	19	5.3
Comunicación/tecnología	Otro: Cloud Data Access	1	19	5.3
Comunicación/tecnología	Otro: CodeVision CVAVR	1	19	5.3
Comunicación/tecnología	Otro: LCD	1	19	5.3
Comunicación/tecnología	Otro: JavaScript Web App	1	19	5.3
Comunicación/tecnología	Otro: IoT Sensor Network	1	19	5.3
Comunicación/tecnología	Otro: IBM SPSS	1	19	5.3
Comunicación/tecnología	Otro: Google Colab	1	19	5.3
Comunicación/tecnología	Otro: Local DB Server	1	19	5.3
Comunicación/tecnología	Otro: MCU CORTEX-M3	1	19	5.3
Comunicación/tecnología	Otro: MAX232	1	19	5.3
Comunicación/tecnología	Otro: Thonny	1	19	5.3
Comunicación/tecnología	Otro: SGP30	1	19	5.3

Continued on next page

(Continued)

Dimensión	Categoría	k	n	%
Comunicación/tecnología	Otro: SD Logging	1	19	5.3
Comunicación/tecnología	Otro: PMS7003	1	19	5.3
Comunicación/tecnología	Otro: NRF24L01 RF Link	1	19	5.3
Comunicación/tecnología	Otro: WordPress	1	19	5.3
Comunicación/tecnología	Otro: WP6003	1	19	5.3
Comunicación/tecnología	Serial	1	19	5.3
Visualización y alertamiento	Tablero	9	19	47.4
Visualización y alertamiento	Módulo de alarma	5	19	26.3
Visualización y alertamiento	Pantalla local	4	19	21.1
Visualización y alertamiento	Gráfico de serie temporal	2	19	10.5
Visualización y alertamiento	Índice AQI por color	1	19	5.3
Visualización y alertamiento	Visualización en mapa	1	19	5.3
Visualización y alertamiento	Alerta médica	1	19	5.3
Visualización y alertamiento	Visualización del modelo	1	19	5.3
Visualización y alertamiento	Gráfico de riesgo	1	19	5.3
Contexto de despliegue	Interior	14	19	73.7
Contexto de despliegue	Urbano	11	19	57.9
Contexto de despliegue	Exterior	6	19	31.6
Contexto de despliegue	Residencial	4	19	21.1
Contexto de despliegue	Industrial	3	19	15.8
Contexto de despliegue	Campus	2	19	10.5
Contexto de despliegue	Centro de salud	2	19	10.5
Contexto de despliegue	Aula educativa	1	19	5.3
Contexto de despliegue	Desierto	1	19	5.3

Continued on next page

(Continued)

Dimensión	Categoría	k	n	%
Contexto de despliegue	Salud personalizada	1	19	5.3
Contexto de despliegue	Rural	1	19	5.3
Hardware y sensores	Sensor PM	10	19	52.6
Hardware y sensores	Sensor temperatura-humedad	9	19	47.4
Hardware y sensores	Sensor de CO	8	19	42.1
Hardware y sensores	MCU Arduino	7	19	36.8
Hardware y sensores	Sensor de CO2	5	19	26.3
Hardware y sensores	Sensor de VOC	4	19	21.1
Hardware y sensores	SBC Raspberry Pi	3	19	15.8
Hardware y sensores	MCU ESP32	3	19	15.8
Hardware y sensores	Nodos sensores IoT	2	19	10.5
Hardware y sensores	Módulo de alarma	2	19	10.5
Hardware y sensores	Sensor de SO2	2	19	10.5
Hardware y sensores	MCU genérico	2	19	10.5
Hardware y sensores	Sensor multigás	2	19	10.5
Hardware y sensores	Actuador de ventilación	1	19	5.3
Hardware y sensores	Transceptor LoRa	1	19	5.3
Hardware y sensores	Infraestructura BLE	1	19	5.3
Hardware y sensores	Sensor de CH4	1	19	5.3
Hardware y sensores	Sensor de NO2	1	19	5.3
Hardware y sensores	Contador de partículas	1	19	5.3
Hardware y sensores	Otro: WP6003 Device	1	19	5.3
Hardware y sensores	Otro: TGS2201	1	19	5.3
Hardware y sensores	Otro: MultiParameter Unit	1	19	5.3
Hardware y sensores	Módulo RTC	1	19	5.3
Hardware y sensores	Estación de referencia	1	19	5.3
Hardware y sensores	Sensor de humo	1	19	5.3
Hardware y sensores	Analizador de referencia VOC	1	19	5.3
Operación en tiempo real	Bucle continuo	10	19	52.6

Continued on next page

(Continued)

Dimensión	Categoría	k	n	%
Operación en tiempo real	Muestreo por intervalo	10	19	52.6
Operación en tiempo real	Alerta por umbral	6	19	31.6
Operación en tiempo real	Carga por streaming	5	19	26.3
Operación en tiempo real	Recolección de datos en tiempo real	2	19	10.5
Operación en tiempo real	Sincronización de reloj	1	19	5.3
Operación en tiempo real	Corrección de datos en tiempo real	1	19	5.3
Operación en tiempo real	Evento de actualización de ruta	1	19	5.3
Operación en tiempo real	Retardo temporal evaluado	1	19	5.3

Tabla 9. Directriz D3: tabla principal de evidencia cuantitativa (k/n/%; n=19). Elaboración propia.

Frecuencia de Métricas por Grupos Comparables Core (Desempeño)

Unidad comparable	Métrica	k	n	%
Clasificación AQI	Accuracy	3	19	15.8
Predicción PM2.5	MAE	3	19	15.8
Clasificación IAQ con control	Accuracy	2	19	10.5
Predicción PM2.5	MAPE	2	19	10.5
Predicción PM2.5	R2	2	19	10.5
Predicción PM2.5	RMSE	2	19	10.5
Clasificación AQI	Concordancia de clase AQI	1	19	5.3
Clasificación AQI	Tasa de entrega	1	19	5.3
Clasificación AQI	Rendimiento de transferencia	1	19	5.3
Estimación AQI/IAQ	Evaluación de AQI	1	19	5.3
Estimación AQI/IAQ	MAPE	1	19	5.3
Estimación AQI/IAQ	MSE	1	19	5.3
Estimación AQI/IAQ	Correlación de Pearson	1	19	5.3

Continued on next page

(Continued)

Unidad comparable	Métrica	k	n	%
Estimación AQI/IAQ	R2	1	19	5.3
Estimación AQI/IAQ	RMSE	1	19	5.3
Estimación AQI/IAQ	Error de desviación estándar	1	19	5.3
Clasificación IAQ con control	Tasa de error	1	19	5.3
Clasificación IAQ con control	Clase de calidad de gas	1	19	5.3
Clasificación IAQ con control	Tiempo de inferencia	1	19	5.3
Clasificación IAQ con control	Pérdida	1	19	5.3
Clasificación IAQ con control	Recompensa media	1	19	5.3
Clasificación IAQ con control	Uso de memoria	1	19	5.3
Clasificación IAQ con control	Lecturas PPM	1	19	5.3
Clasificación IAQ con control	Precisión	1	19	5.3
Predicción PM2.5	NMSE	1	19	5.3
Predicción PM2.5	NRMSE	1	19	5.3

Tabla 10. Resultados de desempeño: frecuencia de métricas en grupos comparables core (k/n/%; n=19).

Elaboración propia.

Anexo IV

Base Principal de 54 Reglas del Motor Difuso

AQI base	Concurrencia	Persistencia	Salida
Good	Baja	Baja	Good
Good	Baja	Media	Good
Good	Baja	Alta	Moderate
Good	Media	Baja	Good
Good	Media	Media	Moderate
Good	Media	Alta	Moderate
Good	Alta	Baja	Moderate
Good	Alta	Media	Moderate
Good	Alta	Alta	Unhealthy for Sensitive Groups
Moderate	Baja	Baja	Moderate
Moderate	Baja	Media	Moderate
Moderate	Baja	Alta	Unhealthy for Sensitive Groups
Moderate	Media	Baja	Moderate
Moderate	Media	Media	Unhealthy for Sensitive Groups
Moderate	Media	Alta	Unhealthy for Sensitive Groups
Moderate	Alta	Baja	Unhealthy for Sensitive Groups
Moderate	Alta	Media	Unhealthy for Sensitive Groups
Moderate	Alta	Alta	Unhealthy
Unhealthy for Sensitive Groups	Baja	Baja	Unhealthy for Sensitive Groups
Unhealthy for Sensitive Groups	Baja	Media	Unhealthy for Sensitive Groups
Unhealthy for Sensitive Groups	Baja	Alta	Unhealthy

Continued on next page

(Continued)

AQI base	Concurrencia	Persistencia	Salida
Unhealthy for Sensitive Groups	Media	Baja	Unhealthy for Sensitive Groups
Unhealthy for Sensitive Groups	Media	Media	Unhealthy
Unhealthy for Sensitive Groups	Media	Alta	Unhealthy
Unhealthy for Sensitive Groups	Alta	Baja	Unhealthy
Unhealthy for Sensitive Groups	Alta	Media	Unhealthy
Unhealthy for Sensitive Groups	Alta	Alta	Very Unhealthy
Unhealthy	Baja	Baja	Unhealthy
Unhealthy	Baja	Media	Unhealthy
Unhealthy	Baja	Alta	Very Unhealthy
Unhealthy	Media	Baja	Unhealthy
Unhealthy	Media	Media	Very Unhealthy
Unhealthy	Media	Alta	Very Unhealthy
Unhealthy	Alta	Baja	Very Unhealthy
Unhealthy	Alta	Media	Very Unhealthy
Unhealthy	Alta	Alta	Hazardous
Very Unhealthy	Baja	Baja	Very Unhealthy
Very Unhealthy	Baja	Media	Very Unhealthy
Very Unhealthy	Baja	Alta	Hazardous
Very Unhealthy	Media	Baja	Very Unhealthy
Very Unhealthy	Media	Media	Hazardous
Very Unhealthy	Media	Alta	Hazardous
Very Unhealthy	Alta	Baja	Hazardous
Very Unhealthy	Alta	Media	Hazardous
Very Unhealthy	Alta	Alta	Hazardous
Hazardous	Baja	Baja	Hazardous

Continued on next page

(Continued)

AQI base	Concurrencia	Persistencia	Salida
Hazardous	Baja	Media	Hazardous
Hazardous	Baja	Alta	Hazardous
Hazardous	Media	Baja	Hazardous
Hazardous	Media	Media	Hazardous
Hazardous	Media	Alta	Hazardous
Hazardous	Alta	Baja	Hazardous
Hazardous	Alta	Media	Hazardous
Hazardous	Alta	Alta	Hazardous

Tabla 11. Base principal de 54 reglas del motor difuso implementado.